

Prediction of Success in Neurofeedback Treatment for Attention-Deficit Hyperactivity Disorder before Starting Treatment

Nikoo Khanahmadi^{1,2}, M.Sc., Mohammad Reza Yousefi^{1,2}, Assistant Professor

¹Department of Electrical Engineering- Najafabad Branch, Islamic Azad University, Najafabad, Iran

²Smart Microgrid Research Center- Najafabad Branch, Islamic Azad University, Najafabad, Iran
nikoo.ahmadi92@gmail.com, mr-yousefi@iaun.ac.ir

Abstract

In this paper, the method of predicting the treatability of patients suffering from hyperactivity with neurofeedback training with the help of extracting the frequency band of the electroencephalogram (EEG) signal and using the brain-functional communication evaluation criterion is done to determine the person's treatability before starting the neurofeedback treatment. This algorithm consists of six steps: In the first step, a data set of EEG signal recording during neurofeedback stimulation from 60 students in the age group of 7 to 14 years (regardless of gender) with hyperactivity in two treatable and non-treatable classes was obtained from the Mendelian database. In the second step, primary filtering has been done to reduce the noise of the data set using a pre-processing block. In the third step, the frequency distribution of the alpha and beta bands is extracted from the noise reduction signals. In this type of data, the difference in the EEG components of each group can be expressed by measuring brain-functional communication and using the phase lock index (PLI), which is used to detect the existence of a connection between the brain lobes involved once using the probability value index. In the t-test statistical test and to increase the accuracy, the genetic algorithm was used to identify the effective electrodes in the treatment. So, the fourth step is to extract the feature, which is to measure the amount of brain communication in the brain signal recording electrodes. In the fifth step, it is to reduce the feature space, the results show that the lobes involved during neurofeedback stimulation are the frontal and central lobes, and among the 32 EEG recording channels, only the data of 6 channels C3, FZ, F4, CZ, C4, and F3 show a significant difference in the amount of brain communication during stimulation. and finally, in the sixth step, by using different classifications, the output of the combination of classifications was the label of one of two classes, treatable or non-treatable. In this proposed method, the correctness criterion is used to express the research result, and finally the percentage of correctness obtained is 90.6%.

Keywords: Brain communication network, electroencephalogram, genetic algorithm, hyperactivity, neurofeedback, prediction

Received: 30 December 2022

Revised: 7 March 2023

Accepted: 23 April 2023

Corresponding Author: Dr. Mohammad Reza Yousefi

Citation: N. Khanahmadi, M.R. Yousefi, "Prediction of success in neurofeedback treatment for attention-deficit hyperactivity disorder before starting treatment", Journal of Intelligent Procedures in Electrical Technology, vol. 16, no. 63, pp. 39-60, September 2025 (in Persian).

پیش‌بینی موفقیت در درمان نوروفیدبک برای بیماران اختلال نقص توجه و بیش‌فعالی پیش از شروع درمان

نیکو خان احمدی^{۱،۲}، دانش‌آموخته کارشناسی ارشد، محمدرضا یوسفی^{۱،۲}، استادیار

۱- دانشکده مهندسی برق - واحد نجف‌آباد، دانشگاه آزاد اسلامی، نجف‌آباد، ایران

۲- مرکز تحقیقات ریزشبکه‌های هوشمند- واحد نجف‌آباد، دانشگاه آزاد اسلامی، نجف‌آباد، ایران

nikoo.ahmadi92@gmail.com, mr-yousefi@iaun.ac.ir

چکیده: در این مقاله روش پیش‌بینی درمان‌پذیری بیماران مبتلا به بیش‌فعالی با آموزش نوروفیدبک به کمک استخراج باند فرکانسی سیگنال الکتروانسفالوگرام (EEG) و با استفاده از معیار ارزیابی ارتباطات مغزی-عملکردی انجام شده تا قبل از شروع درمان نوروفیدبک درمان‌پذیری شخص تشخیص داده شود. این الگوریتم شامل شش مرحله است: در گام اول یک مجموعه داده از ثبت سیگنال EEG حین تحریک نوروفیدبک از ۶۰ دانش‌آموز در رده سنی ۷ تا ۱۴ سال (بدون توجه به جنسیت) مبتلا به بیش‌فعالی در دو کلاس درمان‌پذیر و درمان‌ناپذیر از پایگاه داده مندلی دریافت شده است. در گام دوم فیلترینگ اولیه برای کاهش نویز مجموعه داده‌ها با استفاده از یک بلوک پیش‌پردازش انجام شده است. در گام سوم توزیع فرکانسی باند آلفا و بتا از سیگنال‌های کاهش نویز شده استخراج شده است. در این نوع داده تفاوت در اجزای EEG هر گروه با استفاده از سنجش ارتباطات مغزی-عملکردی و به کمک شاخص قفل فاز (PLI) قابل بیان بوده که برای تشخیص وجود ارتباط بین لوب‌های مغزی درگیر یک‌بار با استفاده از شاخص مقدار احتمال (PV) در آزمون آماری تی-تست و برای افزایش صحت، از الگوریتم ژنتیک برای تشخیص الکتروادهای ثبت سیگنال مغزی می‌باشد در گام پنجم یعنی کاهش فضای ویژگی، نتایج نشان می‌دهند که ارتباطات مغزی در الکتروادهای ثبت سیگنال مغزی می‌باشد در گام پنجم یعنی کاهش فضای ویژگی، نتایج نشان می‌دهند که لوب‌های درگیر هنگام تحریک نوروفیدبک، لوب‌های فرونتال و سنترال هستند و از بین ۳۲ کانال ثبت EEG فقط داده‌های مربوط به ۶ کانال C3، F4، CZ، FZ، C4 و F3 تفاوت معناداری در میزان ارتباطات مغزی حین تحریک از خود نشان می‌دهند و در نهایت گام ششم با استفاده از طبقه‌بندی‌های مختلف، خروجی ترکیب طبقه‌بندها برچسب یکی از دو کلاس درمان‌پذیر یا درمان‌ناپذیر بوده است. در این روش پیشنهادی از معیار صحت برای بیان نتیجه پژوهش استفاده شده و در نهایت درصد صحت به‌دست آمده ۹۰/۶ درصد است.

کلمات کلیدی: الکتروانسفالوگرام، الگوریتم ژنتیک، بیش‌فعالی، پیش‌بینی، شبکه ارتباطات مغزی، نوروفیدبک

تاریخ ارسال مقاله: ۱۴۰۱/۱۰/۹

تاریخ بازنگری مقاله: ۱۴۰۱/۱۲/۱۶

تاریخ پذیرش مقاله: ۱۴۰۲/۲/۳

نام نویسنده‌ی مسئول: دکتر محمدرضا یوسفی

نشانی نویسنده‌ی مسئول: نجف‌آباد- بلوار دانشگاه- دانشگاه آزاد اسلامی واحد نجف‌آباد- دانشکده مهندسی برق

۱- مقدمه

اختلال بیش‌فعالی- نقص توجه^۱ (ADHD) نوعی اختلال رفتاری است که بیشتر در کودکان مورد توجه قرار می‌گیرد [۱،۲]. این اختلال با مشاهده رفتارهای غیرعادی مانند بی‌قراری، عدم-تمرکز و توجه و همچنین تکانش‌گری^۲ (ADD) بیش‌ازحد توسط والدین یا معلمان در مدرسه قابل تشخیص است، به‌این‌ترتیب که کودک رفتار نابهنجاری از خود نشان داده و یا در یادگیری مباحث کم‌توان است. از طرفی این نوع اختلال با استفاده از تست‌های روانشناسی توسط درمانگر قابل تشخیص نیز است و در صورت اقدام به‌موقع و در سنین پایین‌تر اکثراً قابل درمان است. مطابق گزارش‌های آماری میزان این اختلال در هر دو جنسیت زن و مرد وجود دارد و شیوع این بیماری در پسران ۳ برابر بیشتر از دختران است. میزان شیوع این بیماری در میان کودکان زیر ۱۸ سال ۷/۲ درصد و در بین بزرگسالان ۳/۴ درصد است [۳،۴]. این اختلال روانشناسی به‌گونه‌ای است که در همه افراد علائم مشابه ندارد و بسته به میزان آن شخص بیمار رفتار متفاوتی از خود نشان می‌دهد. به‌طور کلی سه نوع اختلال نقص توجه و بیش‌فعالی وجود دارد که عبارتند از: الف- اختلال نقص توجه، ب- بیش‌فعالی و تکانش‌گری و ج- ترکیبی (اختلال نقص-توجه، بیش‌فعالی و تکانش‌گری) [۵].

لوب گیجگاهی^۳ مربوط به کارکردهای شنیداری-زبانی است که در بعضی از کودکان دارای ADHD به‌صورت نابهنجار است. لوب آهیانه‌ای نیز در سبب‌شناسی ADHD مهم است، زیرا این ناحیه مربوط به کارکردهای توجه است. ناحیه پس‌سری مربوط به پردازش دیداری است که بر اساس مطالعات صورت‌گرفته در کودکان دارای این اختلال حجم ماده سفید و خاکستری پس‌سری چپ به میزان ۹ درصد کاهش می‌یابد [۶]. ناحیه ی لیمبیک یکی از نواحی مغزی است که در ADHD دخیل است و درنهایت مطابق تحقیقات انجام شده روی فعالیت‌های الکتریکی مغز، در این اختلال فعالیت لوب‌های پیشانی کاهش می‌یابد و مسئله جالب توجه اینکه کودکان مبتلا به ADHD به محرک‌های بینایی خاصی توجه می‌کنند [۷].

مطابق پژوهش‌های انجام شده ناهنجاری‌های سلولی فقط در پنجمین تا هفتمین ماه رشد جنین رخ می‌دهند که این نکته این دیدگاه را تقویت می‌کند که اختلال‌های یادگیری ناشی از نقص‌های نامحسوس در مغز، از بدو تولد است. یکی از محتمل‌ترین مکان‌ها برای این نقص، لوب گیجگاهی است؛ ناحیه‌ای مربوط به زبان که در هر دو نیمکره مغز مشاهده می‌شود. در فرد سالم، سطح گیجگاهی سمت چپ معمولاً بزرگ‌تر از سمت راست است؛ با این حال، در افراد مبتلا به این اختلال، هر دو قسمت از مغز به یک اندازه است. همچنین تصویر فعالیت سیگنال الکتروانسفالوگرام (EEG) در کودکان مبتلا به این اختلال غیرطبیعی است. به‌ویژه وجود فرکانس‌های کوتاه EEG در نواحی پیشانی مغز این کودکان، بیشتر است و این نشان می‌دهد که رشد ساختارهای مغزی که مسئول توجه و سازمان‌دهی اطلاعات هستند، با تأخیر همراه است. از طرفی بخش‌های عمده‌ای از مغز، مانند نیمکره چپ، بخش پیشین قطعه پیشانی، آهیانه-گیجگاهی^۴ و پس‌سری-گیجگاهی^۵ در این کودکان از فعالیت کمتری برخوردارند. مکان‌های مشخص شنیداری که بازشناسی صداها را معین می‌کنند، در این کودکان وجود ندارد؛ بنابراین درک آنان از بعضی کلمه‌ها ناقص است. دانشمندان هنوز دلیل مشخصی برای علت به وجود آمدن بیش‌فعالی شناسایی نکرده‌اند، ولی آنچه که مشخص است، علت اصلی این بیماری نیز مانند بسیاری از بیماری‌ها، عامل‌های ژنتیکی است.

نحوه تشخیص این اختلال مانند برخی از بیماری‌ها آسان نیست زیرا کودکان به‌طور طبیعی ممکن است در شرایط مختلف خسته شوند و یا نخواهد به چیزی توجه کنند و یا تحت تأثیر استرس و اضطراب هر یک از علائم بیش‌فعالی را داشته باشند ولی به این اختلال مبتلا نباشند. حداقل زمان لازم برای تشخیص گذاری این اختلال ۶ ماه است، به عبارت دیگر کودک باید حداقل ۶ ماه علائم این اختلال را داشته باشد تا روان‌پزشک بتواند تشخیص قطعی اختلال نقص‌توجه-بیش‌فعالی را بدهد. تشخیص بیش‌فعالی در کودکان زیر ۶ سال بسیار دشوار است چون آن‌ها مرتب در طی رشد و نمو در حال تغییر هستند. در حالت عادی کودکان بیش‌فعال مدام در حال بی‌قراری و انجام رفتارهای غیرطبیعی در مقایسه با کودکان سالم هستند که لازمه تشخیص اختلال بیش‌فعالی-کم‌توجهی در آن‌ها مواردی مانند داشتن علائم بیشتر از یک موقعیت توسط کودک، دیدن علائم در طیف وسیعی از رفتارهای کودک، شروع علائم قبل از ۷ سالگی و ادامه داشتن علائم بیشتر از ۶ ماه است [۸].

تاکنون تلاش‌های زیادی برای درمان این اختلال صورت گرفته ولی بهترین روش درمان ارائه‌شده برای درمان این اختلال نوروفیدبک^۶ است. نوروفیدبک به معنی آموزش دادن مغز توسط خود مغز است [۹،۱۰]. در حقیقت مغز با بازخوردهایی که از

بدن و محیط اطراف خود می‌گیرد، به کنترل و تنظیم کارکردهای مختلف جسمی و روانی و تعامل با محیط می‌پردازد [۱۱،۱۲]. به عبارت دیگر نوروفیدبک معمولاً تحریک صوتی یا تصویری را ارائه می‌دهد که در نهایت بیمار در پاسخ به این تحریک‌ها بازخورد مثبت یا منفی از خود نشان می‌دهد که بازخورد مثبت و منفی به ترتیب برای فعالیت‌های مغزی مطلوب یا نامطلوب ارائه می‌شود. دستگاه نوروفیدبک با اطلاعاتی که از امواج مغزی ارائه می‌دهد، به مغز کمک می‌کند تا فعالیت‌ها و کارکرد خود را به شکلی مطلوب تنظیم نماید. در این روش با انعکاس فعالیت‌های جاری و حاکم بر مغز در هنگام فعالیت، به آن نشان داده می‌شود که "الآن و در این لحظه، در چه وضعیتی به سر می‌برد" و به بیمار می‌آموزد که برای انجام یک تکلیف خاص، به چه آرایشی از امواج مغزی، نیاز دارد [۱۳،۱۴]. بنابراین بازخوردی که مغز از خود دریافت می‌کند بر اساس امواج مغزی است و هیچ‌گونه جریان الکتریکی وارد مغز نمی‌گردد و فعالیت الکتریکی مغز به‌سادگی به کامپیوتر انتقال داده می‌شود [۱۵].

تحقیقات نشان داده که تحریک درست و به‌موقع مغز باعث رشد و جلوگیری از مرگ سیناپس‌ها می‌شود و عدم تحریک آن‌ها باعث کاهش تدریجی فعالیت‌ها و تأخیر رشد عصبی و مرگ سیناپسی و به دنبال آن بروز علائم اختلالات مختلف می‌گردد؛ در نتیجه نوروفیدبک که آموزشی مؤثر در راستای افزایش توجه و تمرکز و روشی جهت تحریک مغز و بازداری از مرگ زود هنگام سیناپس‌ها است، می‌تواند از این عوارض جلوگیری کند [۱۶]. نوروفیدبک در واقع یک فرایند آموزشی است که در آن مغز خود تنظیمی را یاد می‌گیرد و پس از چندین جلسه تمرین و تکرار، مغز می‌تواند با آرایش جدیدی از امواج به فعالیت روزانه خود ادامه دهد. نکته مهم در درمان نوروفیدبک این است که هدف از تنظیم امواج، تغییر قدرت و دامنه موج است و نه پهنای نوع موج. برای مثال موج آلفا به بتا تغییر نمی‌یابد بلکه اگر درمانگر تشخیص دهد موج آلفا در منطقه پیشانی مغز دارای قدرت بیش از اندازه است، هدف کاهش شدت آن است و برای مثال آن را از آلفای با شدت ۱۲ میکرو-ولت به ۷ میلی-ولت کاهش می‌دهد. در این روش، به‌منظور بهبود نتایج حاصل از درمان و پایداری بیشتر آثار درمانی، تعداد جلسه‌ها باید به حد کفایت باشد تا زمانی که درمان تکمیل شود. مدت معمول جلسه‌ها بین ۴۰ تا ۴۵ جلسه و ۳۰-۴۵ دقیقه در هر جلسه بوده و ممکن است در برخی موارد کمی طولانی‌تر یا کوتاه‌تر باشد؛ که این جلسه‌ها حداقل ۲ تا ۳ جلسه در هفته انجام می‌شود. از طرفی درمان‌پذیری^۷ با این روش قطعی نیست و پس از چندین جلسه مشخص می‌گردد که نوروفیدبک می‌تواند مؤثر واقع شود یا خیر. لازمه تشخیص درمان‌پذیری با این روش طی شدن چندین جلسه آموزش از یک سیکل درمانی ۳۰ تا ۴۵ جلسه‌ای است تا با ثبت سیگنال مغزی فرد میزان بهبودی، نسبت به قبل از شروع آموزش مشخص شود و در صورت نبود تغییرات چشم‌گیر روند درمان به‌طور کامل متوقف گردد. امواج مغزی دارای اجزای فرکانسی مختلفی است که شامل باندهای دلتا (کمتر از ۴ هرتز)، تتا (۴-۸ هرتز)، آلفا (۸-۱۳ هرتز)، بتا (۱۳-۳۰ هرتز) و گاما (۳۰-۱۰۰ هرتز) بوده که هر یک نشان‌دهنده عملکرد فیزیولوژیکی خاص در مغز هستند.

به‌طور کلی هفت نوع نوروفیدبک برای درمان اختلالات مختلف وجود دارد که عبارتند از: نوروفیدبک فرکانس/قدرت، نوروفیدبک بالقوه پتانسیل قشر آهسته مغز^۸ (SCP-NF)، سیستم نوروفیدبک کم انرژی^۹ (LENS)، نوروفیدبک هموآنسفالوگرافی^{۱۰} (HEG)، نوروفیدبک منبع Z زندگی^{۱۱} (LZS)، توموگرافی الکترومغناطیسی با وضوح پایین^{۱۲} (LORETA) و تصویربرداری رزونانس مغناطیسی عملکردی^{۱۳} (fMRI).

پروتکل‌های درمان نوروفیدبک عمدتاً بر درمان باند آلفا، بتا، دلتا، تتا و گاما یا ترکیبی از آن‌ها مانند نسبت آلفا/بتا، آلفا/تتا، بتا/تتا و غیره تمرکز دارند. با این حال، رایج‌ترین پروتکل‌های مورد استفاده عبارتند از: آلفا، بتا، تتا و نسبت آلفا/بتا [۱۷]. هدف از آموزش نوروفیدبک، اصلاح EEG نابهنجار است که نتیجه آن ارتقاء عملکرد رفتاری و شناختی در فرد است. از این‌رو یک پروتکل مناسب نوروفیدبک می‌تواند کمبود نسبت باندهای آلفا و بتا را در سیگنال مغزی فرد بیمار نسبت به حالت نرمال را جبران نماید [۱۸،۱۹]. وقتی شخص در وضعیت‌های مختلف ادراکی-شناختی^{۱۴} قرار می‌گیرد انتشار اطلاعات از طریق نوسانات نورون‌های مغزی انجام می‌شود که بررسی این نوسانات و به‌طور کلی ارتباط میان بخش‌های مختلف مغز می‌تواند اطلاعات مفیدی در مورد نحوه واکنش مغز در وضعیت‌های مختلف را بیان کند [۲۰،۲۱]. مطابق مطالعات انجام شده در گذشته برای

تشخیص درمان بیش فعالی با روش نوروفیدبک، بیمار باید چند جلسه آموزش را سپری کند تا بتوان درمان‌پذیر بودن یا درمان‌ناپذیری افراد را مشخص کرد که این نتایج با درصد صحت متفاوت نشان داده شده است [۲۲،۲۳].

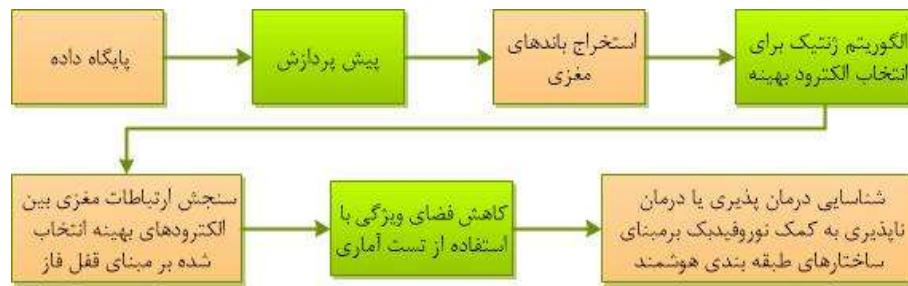
اصولاً در آموزش نوروفیدبک دو جهت وجود دارد. یا تمرکز بر فرکانس‌های پایین (آلفا یا تتا) برای تقویت آرامش است و یا تمرکز بر فرکانس‌های بالا (بتا پایین، بتا و تتا) برای تقویت فعال‌سازی، سازمان‌دهی و مهار حواس‌پرتی است [۲۴]، که در روش اول چشم‌ها بسته و در روش دوم چشم‌ها باز هستند که به‌طور کلی روش اول برای کودکان مناسب نیست در حالی که کودکان و بزرگسالان می‌توانند تحت روش دوم قرار گیرند. نوروفیدبک در درمان بسیاری از بیماری‌ها و اختلالات روانی استفاده شده است. مطالعات نشان داده که افراد مبتلا به اختلال ADHD در مقایسه با افراد عادی فعالیت امواج مغزی کندتر (تتا) و فعالیت بتا کمتری دارند. در درمان ADHD، هدف، کاهش فعالیت مغز در باند تتا و افزایش فعالیت آن در باند بتا (یا کاهش نسبت تتا/بتا) در رأس (الکتروود) است [۲۵]. این درمان در کاهش بیش‌فعالی مؤثر است و افزایش تمرکز، افزایش وضعیت نمرات، رضایت والدین از رفتار کودکان و بهبود شاخص‌های توجه پایدار را به همراه دارد [۲۶،۲۷].

با توجه به مطالعات انجام شده در زمینه کاربرد نوروفیدبک برای درمان بیماری بیش‌فعالی، ولی پیش‌بینی درمان‌پذیری بیماران مبتلا به بیش‌فعالی با روش نوروفیدبک یکی از مواردی است که هنوز روش مؤثر و درصد صحت چشم‌گیری برای آن ارائه نشده است. هدف این مقاله پیش‌بینی درمان‌پذیری با روش نوروفیدبک با درصد صحت بالا نسبت به روش‌های موجود پیش از شروع درمان است که در آن میزان ارتباطات مغزی در لوب‌های مختلف مغز سنجیده شده و در نهایت از الگوریتم ژنتیک برای کاهش فضای ویژگی یعنی الکتروودهای مؤثر در درمان نوروفیدبک استفاده شده و تعداد آن‌ها را از ۳۲ کانال مغزی به ۶ کانال مغزی تعمیم داده است. از الگوریتم ژنتیک برای بهبود دقت طبقه‌بندی و انتخاب ویژگی‌های بهینه استفاده شده به‌طوری که هر بیت از یک آرایه دارای مقدار صفر یا یک است که مقدار یک بیان‌کننده وجود این ویژگی و مقدار صفر عدم وجود آن ویژگی را در فضای ویژگی نشان می‌دهد، بنابراین موقعیت یک ویژگی در فضای انتخاب شده با عدد یک (وجود) یعنی درمان‌پذیری و یا عدد صفر (عدم وجود) یعنی درمان‌ناپذیری به‌صورت باینری کدگذاری می‌شود. از نوآوری‌ها روش پیشنهادی می‌توان به موارد زیر اشاره کرد:

- افزایش درصد صحت نتایج نسبت به روش‌های دیگر
 - تشخیص لوب‌های مغزی مؤثر در درمان نوروفیدبک با استفاده از شاخص قفل‌فاز و شاخص آماری PV
 - استفاده از الگوریتم ژنتیک برای کاهش فضای ویژگی و در نهایت تشخیص کانال‌های بهینه در درمان نوروفیدبک
 - کاهش تعداد کانال‌های ثبت سیگنال مغزی از ۳۲ به ۶ کانال مؤثر در درمان نوروفیدبک
 - پیش‌بینی درمان‌پذیری یا درمان‌ناپذیری کودکان مبتلا به بیش‌فعالی پیش از شروع درمان از روی تحلیل باند فرکانسی آلفا و بتا سیگنال مغزی و همچنین میزان ارتباط عملکردی مغز
- ساختار مقاله به این شرح است. پس از بیان مسئله و اهمیت موضوع درمان‌پذیری با آموزش نوروفیدبک، در بخش دوم روش پیشنهادی شامل شش مرحله پیش‌پردازش، پردازش، استخراج ویژگی، کاهش فضای ویژگی و طبقه‌بندی است و در نهایت خروجی، برچسب درمان‌پذیر یا درمان‌ناپذیر است. در بخش سوم مواد و روش شامل مشخصات شرکت‌کنندگان، پیش‌پردازش و پردازش داده‌ها اشاره شده است. در بخش چهارم تجزیه و تحلیل نتایج با استفاده از شاخص‌های مختلف توضیح داده شده است. در انتها نتیجه‌گیری و پیشنهادها در بخش پنجم آمده است.

۲- روش پیشنهادی

در این قسمت شش گام اساسی روش پیشنهادی مطابق شکل (۱) بیان شده که شامل جمع‌آوری داده، پیش‌پردازش، پردازش، استخراج ویژگی، کاهش فضای ویژگی و طبقه‌بندی است و در پایان نتایج حاصل از شبیه‌سازی و مقادیر صحت برای اعتبارسنجی روش پیشنهادی ارائه شده است.



شکل (۱): روش پیشنهادی شامل شش مرحله

Figure (1): Block diagram of the proposed method

در گام اول از داده‌های حاصل از ثبت سیگنال مغزی در طول تحریک نوروفیدبک در جلسات ۱۰-۲۰ دوره درمانی استفاده شده است. نویزهای ایجاد شده در سیگنال که به دلیل آرتیفکت‌های حرکتی، نویزهای محیطی و نویز برق شهر بودند همگی حذف شده‌اند. گام دوم استخراج باند آلفا و بتا از سیگنال مغزی به کمک یک فیلتر میان‌گذر باترورث^{۱۵} است. گام سوم استخراج ویژگی یعنی همان ارتباطات مغزی عملکردی^{۱۶} به کمک شاخص قفل‌فاز^{۱۷} است که وجود ارتباط بین لوب‌های مغزی را تشخیص داده و به کمک یک شاخص آماری^{۱۸} در تست آماری تی^{۱۹} مقدار آن را گزارش می‌کند؛ و به این ترتیب کانال‌های بهینه انتخاب می‌شوند. گام بعدی انتخاب الکتروده بهینه با استفاده از الگوریتم ژنتیک^{۲۰} است که تعداد ۳۲ الکتروده را به ۶ الکتروده کاهش داده است. سپس الکترودهای استخراج شده توسط الگوریتم ژنتیک با الکترودهای انتخاب شده توسط تست آماری مقایسه شده و ۶ الکتروده مشترک به‌عنوان الکترودهای بهینه انتخاب می‌گردد. در نهایت ماتریس ویژگی به‌صورت یک ماتریس ۱۲۰۰ (تعداد تکرار آزمایش) سطر در ۳۶ (تعداد ویژگی) ستون است که برای هر باند آلفا و بتا به‌صورت جداگانه محاسبه گردیده است. عدد ۳۶ به این دلیل است که هر یک از ۶ کانال انتخابی به کمک الگوریتم ژنتیک با خود و کانال‌های دیگر ارتباط دارد. گام پنجم طبقه‌بندی است که در آن از ترکیب طبقه‌بندی‌های مختلف استفاده شده است. در این مرحله ماتریس ویژگی که از مرحله قبل استخراج شده به‌عنوان ورودی طبقه‌بندی در نظر گرفته می‌شود. خروجی طبقه‌بندی ماتریس برچسب با ابعاد ۱۲۰۰ (تعداد تکرار آزمایش) سطر در یک (عدد برچسب) ستون است که عدد صفر فرد درمان‌ناپذیر و عدد یک فرد درمان‌پذیر را مشخص می‌کند. برای اعتبارسنجی روش پیشنهادی برای طبقه‌بندی کننده‌های به‌کار برده شده از شاخص‌های صحت^{۲۱} استفاده می‌شود. به‌منظور ارزیابی طبقه‌بندی نیز از روش کافولد استفاده شده و k برابر ۵ است.

۳- مواد و روش

در این قسمت به مشخصات شرکت‌کنندگان، پیش‌پردازش و پردازش داده‌ها اشاره می‌شود.

۳-۱- شرکت‌کنندگان در تحقیق

یک مجموعه داده از ثبت سیگنال الکتروانسفالوگرام حین تحریک نوروفیدبک از ۶۰ دانش‌آموز (بدون توجه به جنسیت) مبتلا به بیش‌فعالی در دو کلاس از پایگاه داده مندلی^{۲۲} استفاده شده است. دانش‌آموزان به دو گروه درمان‌پذیر (۳۰ نفر) و درمان‌ناپذیر (۳۰ نفر) تقسیم شده‌اند. روش تشخیص درمان‌پذیری یا درمان‌ناپذیری این بیماران به این ترتیب بوده که تمامی این بیماران دوره درمانی ۳۰ الی ۴۵ جلسه‌ای آموزش نوروفیدبک را طی کرده‌اند و درمان‌گر با بررسی روند تغییرات اصلاح الگوی سیگنال مغزی درمان‌پذیری یا درمان‌ناپذیری فرد را تشخیص داده است. این داده‌ها مربوط به جلسات ۱۰ تا ۲۰ دوره درمان بیماران است که بر روی هر یک از آن‌ها ۲۰ بار آزمایش صورت گرفته است؛ بنابراین تعداد دفعات آموزش در جلسات موردنظر ۱۲۰۰ است که با فرکانس نمونه‌برداری ۵۰۰ هرتز در مدت‌زمان ۱/۱ ثانیه حین تحریک ثبت شده است. یعنی ۱۱۰۰ میلی‌ثانیه داده است که با فرکانس نمونه‌برداری ۱۰۰۰ میلی‌ثانیه پس از شروع محرک) ثبت می‌شوند. تعداد نمونه سیگنال ۵۵۰ عدد و ثبت داده با ۳۲ کانال مغزی انجام گرفته است. داده‌های دریافتی به‌صورت فایل با پسوند Text بوده و در نرم‌افزار متلب فراخوانی می‌شوند. در این نوع تحریک دو تصویر متفاوت به بیماران نشان داده شده و از آن‌ها خواسته شده که چشم‌های خود را ببندند و

جزئیات تصاویر را به خاطر بیاورند. نورفیدبک به صورت سه جلسه در هفته (روزهای زوج یا فرد) و هر جلسه به مدت یک ساعت انجام می‌گردد. ارزیابی جامع روند درمان در جلسات ۵، ۱۵ و ۳۰ صورت می‌گیرد و جلسات ارزیابی روان‌پزشک در جلسات ۱۰، ۲۰ و ۴۰ انجام می‌شود. روش اجرا به این صورت بود که ابتدا پیش‌آزمون، سپس آزمون آزمایشی و پس‌از آن پس‌آزمون اجرا گردید.

۲-۳- پیش‌پردازش داده‌ها

سیگنال‌های مغزی در محدوده فرکانسی معنادار ۰/۵ تا ۴۵ هرتز است که برای پردازش آن‌ها از یک فیلتر باترورث میان‌گذر استفاده می‌شود. به‌طور کلی پیش‌پردازش داده‌ها در شش مرحله به ترتیب زیر انجام می‌گیرد:

مرحله اول- آنالیز طیفی سیگنال: با اعمال تبدیل فوری سیگنال حوزه زمان به حوزه فرکانس نگاشت آنالیز طیفی سیگنال انجام می‌شود. سپس محدوده فرکانسی سیگنال و تابع چگالی طیف توان موردبررسی قرار می‌گیرد و در صورتی که محدوده برای سیگنال مغزی مطلوب نباشد، مجدداً ثبت داده انجام می‌شود.

مرحله دوم- حذف نویز با استفاده از فیلترناچ^{۲۳}: برای حذف نویز برق شهر و بهینه‌سازی سیگنال و تنظیم خط مبنا از یک فیلتر ناچ که یک فیلتر فرکانس گزین با فرکانس قطع ۵۰ هرتز می‌باشد، استفاده شده است که پهنای باند آن روی یک دهم تعدیل شده بر فرکانس نمونه برداری است. (یعنی پهنای باند ۵۰ تقسیم بر ۵۵۰ (فرکانس نمونه برداری) است.)

مرحله سوم- فیلتر باترورث میان‌گذر: با توجه به اینکه فیلتر باترورث دارای فاز شبه خطی است برای پیش‌پردازش و کاهش نویز داده‌ها مناسب به نظر می‌رسد زیرا الگوهای سیگنال بعد از اعمال فیلتر با شیفت خطی تغییر می‌کنند. مرتبه ی فیلتر باترورث با استفاده از الگوریتم مک‌کلان^{۲۴} تخمین زده شد و عدد بدست آمده برای مرتبه ی بهینه‌ی فیلتر عدد ۱۰ می‌باشد. برای طراحی این فیلتر فرکانس‌های قطع بین یک دهم تا ۴۵ هرتز می‌باشد و ضریب ریپل یک دهم هرتز برای باند عبور و قطع است. (یعنی ریپل باند عبور و ریپل باند قطع بر عدد یک دهم با واحد خطی تنظیم شده است). همچنین میزان گذار فرکانسی یک هرتز می‌باشد.

مرحله چهارم- تبدیل موجک برای حذف ضرایب کلیات فرکانس پایین: در این مرحله با اعمال فیلتر بانک تبدیل موجک^{۲۵} برای کاهش نویزهایی با منابع نامشخص در فرکانس‌های پایین از طریق تطبیق‌دهی سیگنال مادر با سیگنال دختر (سیگنال خام) استفاده می‌شود که برای حذف ضرایب کلیات فرکانس پایین نامطلوب و بازسازی مجدد سیگنال در نظر گرفته شده است. درواقع این نویزها، نویز فرکانس پایین ناشی از آرتیفکتهای حرکتی سیگنال است که برای کاهش آن و بهبود نسبت سیگنال به نویز (SNR)^{۲۶} از اعمال فیلتر بانک موجک استفاده می‌گردد.

مرحله پنجم- تبدیل موجک برای حذف ضرایب جزئیات فرکانس بالا: در این مرحله نیز با اعمال فیلتر بانک تبدیل موجک برای کاهش نویزهایی با منابع نامشخص در فرکانس‌های بالا از طریق تطبیق‌دهی سیگنال مادر با سیگنال دختر (سیگنال خام) استفاده می‌شود که برای حذف ضرایب جزئیات فرکانس بالا نامطلوب از سطوح پایین‌تر تجزیه به سطوح بالاتر و بازسازی مجدد سیگنال به‌کار برده می‌شود. در واقع این نویزها، نویز فرکانس پایین ناشی از منابع نویز فرکانس بالا است (در محدوده‌ای خارج از محدوده عملیاتی سیگنال مورد نظر).

در این مقاله سطح تجزیه تبدیل موجک ۵ سطح تجزیه در نظر گرفته شده است. مادر موجک دابیچیز ۱۰ و جزئیات سطح اول به عنوان نویز فرکانس بالا و کلیات سطح پنجم به عنوان نویز فرکانس پایین در نظر گرفته شده و بعد از حذف این نویزها سیگنال مجدداً بازسازی شده است.

مرحله ششم- فیلتر میانگین‌گیر متحرک^{۲۷}: برای هموار کردن سیگنال و کاهش نویز فرکانس بالا و همچنین نویزهای ناشی از آرتیفکتهای حرکتی^{۲۸} از یک فیلتر میانگین‌گیر متحرک استفاده می‌شود. در فیلتر میان‌گیر متحرک نظر به این‌که فرکانس نمونه‌برداری ۵۵۰ هرتز می‌باشد یعنی در هر ثانیه ۵۵۰ نمونه وجود دارد حال اگر طول پنجره حدود ۰/۲ ثانیه در نظر گرفته شود امکان تعدیل نویز فرکانس بالا با فیلتر میان‌گیر متحرک فراهم می‌شود و این عدد معادل ۱۰ نمونه است که الگوی سیگنال از بین نمی‌رود و در مقابل سبب تعدیل نویزهای فرکانس بالا می‌شود.

۳-۳- پردازش داده‌ها

پس از کاهش نویز سیگنال با انجام عملیات فیلتراسیون در مرحله پیش‌پردازش با استفاده از یک فیلتر باترورث، باند فرکانسی آلفا و بتا تفکیک می‌شوند و با شاخص PLV ویژگی مورد نظر که همان بررسی میزان ارتباطات لوب‌های مغزی است استخراج و برای کاهش فضای ویژگی با کمک الگوریتم ژنتیک و آزمون تی تست توسط شاخص PV الکترودهای بهینه انتخاب و داده‌ها به دو کلاس درمان‌پذیر و درمان‌ناپذیر طبقه‌بندی می‌شوند. شاخص PV کمک می‌کند که بدون مراجعه به جدول‌ها توزیع آماری، در مورد پذیرش یا رد فرض صفر تصمیم‌گیری شود. اگر عدد PV برای یک کانال مغزی در دو باند آلفا و بتا زیر ۰/۰۵ باشد، الکتروده مربوط به این کانال انتخاب و در صورتی که بیش از ۰/۰۵ باشد انتخاب نمی‌شود که این اعداد به کمک آزمون آماری تی به‌دست می‌آید. آزمون تی یک روش آماری است که در آن نمونه‌ها به‌صورت تصادفی انتخاب می‌شوند و توزیع نرمال کاملی وجود ندارد. دقت آزمایش به عوامل مختلفی مانند الگوهای توزیع مورد استفاده و انواع تأثیرگذار بر نمونه‌های جمع‌آوری شده بستگی دارد. پس از انجام آزمون یک مقدار به‌عنوان استنتاج آماری احتمال به‌دست می‌آید. در روش پیشنهادی از آزمون T دو نمونه‌ای مستقل استفاده شده است. این آزمایش زمانی انجام می‌شود که نمونه‌هایی از دو گروه، گونه یا جمعیت مختلف مورد مطالعه و مقایسه قرار می‌گیرند. در این بررسی داده‌ها از دو گروه درمان‌پذیر و درمان‌ناپذیر استخراج شده‌اند. این آزمون همچنین به‌عنوان آزمون T مستقل نیز شناخته می‌شود؛ که فرمول آن به‌صورت زیر است:

$$t = \frac{m_A - m_B}{\frac{\sqrt{S^2}}{\sqrt{n_A}} + \frac{\sqrt{S^2}}{\sqrt{n_B}}} \quad (1)$$

که در آن m_A و m_B میانگین نمونه‌ها از دو گروه یا جمعیت مختلف و n_A و n_B اندازه نمونه مربوطه و S^2 انحراف معیار یا واریانس مشترک دو نمونه است [۲۸، ۲۹]. برای پردازش سیگنال EEG در دو باند آلفا و بتا از فیلتر باترورث باندگذر مرتبه ۱۰ استفاده شده است. با توجه به اینکه فیلتر باترورث دارای فاز شبه خطی است برای پیش‌پردازش و کاهش نویز داده‌ها مناسب به نظر می‌رسد زیرا الگوهای سیگنال بعد از اعمال فیلتر با شیف‌ت خطی تغییر می‌کنند [۳۰]. مرتبه فیلتر باترورث با استفاده از الگوریتم مک‌کلان تخمین زده شده و عدد به‌دست آمده برای مرتبه بهینه‌ی فیلتر ۱۰ است. برای طراحی فیلتر فرکانس‌های قطع بین یک‌دهم تا ۴۵ هرتز و ضریب ریبیل یک‌دهم هرتز برای باند عبور و قطع است.

۳-۴- استخراج ویژگی

ویژگی اصلی پژوهشی بررسی وجود ارتباطات مغزی عملکردی بین لوب‌های مغزی هنگام تحریک نوروفیدبک است که استخراج ویژگی به کمک شاخص قفل‌فاز PLV مشخص شده است. اگر دو ناحیه مغز از نظر عملکردی به هم متصل باشند، تفاوت بین فازهای لحظه‌ای سیگنال‌ها از این مناطق مغز باید کمابیش ثابت بماند. از آنجایی که فاز آنی فقط برای سیگنال‌های باند باریک تفسیر فیزیکی دارد، اولین گام در محاسبه مقدار قفل‌فاز یا PLV فیلتر کردن است [۳۱، ۳۲]. برای محاسبه این شاخص در ابتدا فاز هر سیگنال با استفاده از تبدیل هیلبرت به‌دست آمده و اختلاف فاز محاسبه می‌شود. اگر اختلاف فاز در آزمایش‌ها کمی متفاوت باشد، PLV نزدیک به یک و در غیر این‌صورت نزدیک به صفر است. با توجه به آزمایش‌ها یا دوره‌های متعدد سیگنال‌های مغزی فیلتر شده باند باریک از دو کانال EEG، مقدار قفل‌فاز را می‌توان به‌صورت زیر تعریف کرد [۳۳].

$$PLV_t = \frac{1}{N} \left| \sum_{n=1}^N e^{j\theta(t,n)} \right| \quad (2)$$

که در آن N تعداد آزمایش‌ها و $\theta(t,n)$ تفاوت بین فاز لحظه‌ای دو سیگنال در زمان t و آزمایش n است، بنابراین محاسبه PLV ابتدا نیازمند فیلتر کردن داده‌ها در باند فرکانسی مورد نظر و سپس استخراج فاز آنی از طریق تبدیل هیلبرت است که سیگنال‌های واقعی را به یک نمایش پیچیده تبدیل می‌کند. PLV مقادیری را در محدوده $[0, 1]$ می‌گیرد که در آن PLV برابر صفر نشان می‌دهد که هیچ سنکرون فازی وجود ندارد و PLV برابر یک نشان می‌دهد که فاز نسی بین دو سیگنال در طول آزمایش‌ها یکسان است.

۵-۳- کاهش فضای ویژگی

خلاصه الگوریتم ژنتیک در روش پیشنهادی در انتخاب الکتروده به صورت زیر بیان می‌شود:
گام اول- ورود ماتریس داده است که ابعاد آن برای هر باند $۱۲۰۰ \times ۵۵۰ \times ۳۲$ است که به ترتیب تعداد تکرار آزمایش، تعداد نمونه سیگنال و تعداد کانال دستگاه را نشان می‌دهد.

گام دوم- تولید جمعیت اولیه است که برای ایجاد جمعیت، چندین کروموزوم باینری به صورت تصادفی ایجاد می‌شوند که تعداد بیت‌ها در آن برابر تعداد ویژگی‌ها هستند. به این ترتیب که با توجه به ۳۲ الکتروده مورد استفاده ۳۲ ویژگی وجود دارد. یک کروموزوم اولیه با ۳۲ ژن به صورت تصادفی تولید و ژن‌هایی که عدد یک هستند انتخاب و استخراج ویژگی می‌شوند. سپس به طبقه‌بند داده شده تا با توجه به ماتریس برچسب واقعی که ورودی طبقه‌بند است صحت آن کروموزوم به دست آید (صحت برابر است با اختلاف برچسب واقعی با برچسب خروجی طبقه‌بند). بار دوم یک ماتریس تصادفی دیگر به همین ترتیب تولید و صحت تعیین می‌شود. این دو کروموزوم به عنوان کروموزوم‌های والد انتخاب و چندین مرحله تولید نسل انجام می‌شود.

گام سوم- تعیین تابع هزینه بر اساس خطای طبقه‌بندی که باید مقدار این خطا یعنی حاصل مربع اختلاف برچسب واقعی از برچسب بدست آمده از یک طبقه‌بند مینیمم گردد (صحت-۱=خطا).

گام چهارم- در این گام با توجه به معیار برازندگی هر کروموزوم، یک جمعیت جدید به دو روش تقاطع و جهش ایجاد می‌شود. گام پنجم- انتخاب جمعیت مطلوب با توجه به تابع برازندگی^{۲۹} است.

گام ششم- بررسی شرایط خاتمه که دو حالت دارد شامل ارضا نشده است (بازگشت به مرحله ۴) و ارضا شده است (اعلام کروموزوم مطلوب).

در این مقاله روش تقاطع کروموزوم‌های والدین بر مبنای عملگر XOR و جهش بر مبنای روش فلیپ-بیت^{۳۰}، نرخ جهش یک صدم و درصد تقاطع و درصد جهش به ترتیب $۰/۷$ و $۰/۳$ در نظر گرفته شده است. تابع برازش یا تابع هدف میزان خطای طبقه‌بند است که هدف مینیمم‌سازی آن است. همچنین معیار توقف الگوریتم تغییر ناچیز خطا به ازای دو مرحله متوالی از تکرار الگوریتم است و در نهایت در صورت عدم تغییرات کاهش خطا در اجرای متوالی الگوریتم کروموزوم با بالاترین صحت انتخاب و ژن‌های باینری با عدد یک به عنوان الکترودهای بهینه انتخاب می‌گردند (اختلاف کاهش خطای دو مرحله تکرار الگوریتم متوالی ۱۰ به توان منفی ۶ به دست آمده است). صحت و خطا به ترتیب از رابطه‌های (۳) و (۴) تعیین می‌شوند [۳۴،۳۵].

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (۳)$$

$$\text{Error} = 1 - \text{Accuracy} \quad (۴)$$

مقدار تابع برازش (FF) از رابطه زیر تعیین می‌شود که در آن تعداد مرحله‌های تکرار الگوریتم m_1, m_2, \dots, m_{n-1} و m_n در نظر گرفته می‌شود.

$$FF = \text{Error}(m_a) - \text{Error}(m_{n-1}) = 10^{-6} \quad (۵)$$

شکل (۲) تابع هزینه الگوریتم ژنتیک برای انتخاب الکتروده بهینه نشان می‌دهد که به سمت مینیمم شدن پیش می‌رود. با توجه به این که تابع هزینه الگوریتم ژنتیک از روی خطای طبقه‌بند تعیین می‌شود به طوری که اختلاف خطای بین دو مرحله متوالی از ۱۰ به توان ۶ کمتر نشود (این مقدار با تکرار به دست آمده و به عنوان تابع هزینه تعیین شده است) در نتیجه زمانی که اختلاف خطا به این مقدار رسید یعنی الگوریتم در مینیمم مطلق قرار دارد و روند تکرار الگوریتم به پایان می‌رسد.


۴- تجزیه و تحلیل نتایج

در این بخش به بررسی نتایج حاصل از روش پیش‌بینی درمان‌پذیری بیماران ADHD با نوروفیدبک، پرداخته می‌شود و شامل خروجی شش گام اساسی روش پیشنهادی است که شامل جمع‌آوری داده، پیش‌پردازش، پردازش، استخراج ویژگی، کاهش

فضای ویژگی و طبقه‌بندی است و در پایان نتایج حاصل از شبیه‌سازی‌ها و مقادیر صحت برای اعتبارسنجی روش پیشنهادی ارائه شده است.

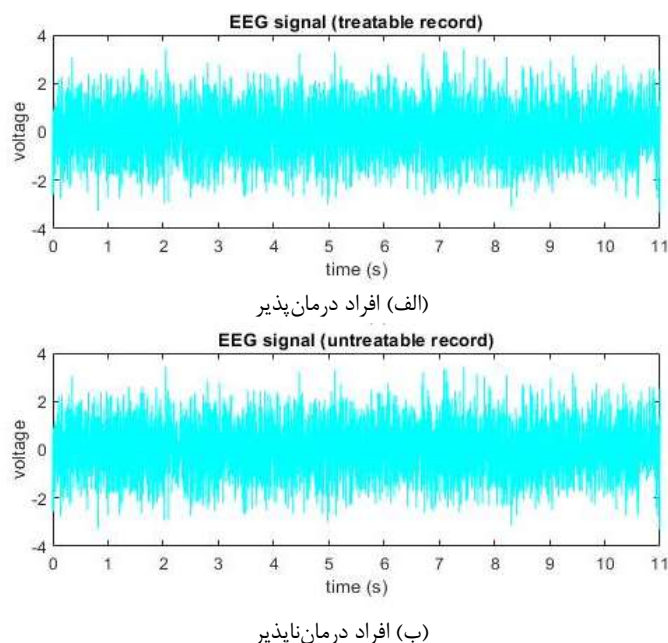
۴-۱- داده‌ها

داده مورد استفاده در این مطالعه ثبت به‌صورت چندکاناله بوده که امکان انتخاب کانال بهینه فراهم شده است. برای فراخوانی داده‌ها، آدرس هر دسته داده نرم‌افزار متلب داده شد و با نوشتن یک حلقه تمامی پایگاه داده در این برنامه فراخوانی شده است. لازم به ذکر است که الگوریتم ارایه شده در این مقاله در محیط متلب R2020b کدنویسی شده است. در ابتدا داده‌های اولیه برای کاهش نویز وارد ساختار پیش‌پردازشی می‌شوند. شکل (۳) خروجی نرم‌افزار متلب برای نمونه سیگنال الکتروانسفالوگرام حین تحریک نوروفیدبک قبل از حذف نویز را نشان می‌دهد.



شکل (۲): تابع هزینه در الگوریتم ژنتیک برای انتخاب الکترود بهینه

Figure (2): Cost function in the genetic algorithm for optimal electrode selection



شکل (۳): سیگنال الکتروانسفالوگرام پیش از اعمال فیلترینگ

Figure (3): EEG signal of people before applying filtering, a) Treatable, b) Non-treatable

این سیگنال برای مدت ۱/۱ ثانیه از ثبت سیگنال الکتروانسفالوگرام حین تحریک ترسیم شده که محور افقی آن زمان و برحسب ثانیه و محور عمودی ولتاژ برحسب میکرو-ولت است که دامنه سیگنال را نشان می‌دهد. مجموعه این داده‌ها به صورت یک فایل فشرده ذخیره شده که محتوی سه ماتریس است. ماتریس اول بنام data بوده که یک ماتریس سه بعدی $1200 \times 55 \times 32$ است که به ترتیب تعداد تکرار آزمایش، تعداد نمونه سیگنال و تعداد کانال ثبت نوروفیدبک را نشان می‌دهد. فرکانس نمونه برداری دستگاه ۵۰۰ هرتز است و زمان ثبت سیگنال ۱/۱ ثانیه است، بنابراین ۵۵۰ نمونه سیگنال وجود دارد ($500 \times 1/1$). ماتریس دومی که به همراه این پایگاه داده ارائه شده است، ماتریس label با بعد 1200×1 است. این ماتریس محتوی برچسب دو کلاس است که برچسب یک برای بیماران درمان پذیر و برچسب صفر برای بیماران درمان ناپذیر در نظر گرفته شده است. در این مطالعه فقط از داده‌های مربوط به کانال‌های C3, FZ, F4, CZ, C4 و F3 استفاده شده است زیرا لوب‌های درگیر در تحریک نوروفیدبک، لوب‌های فرونتال و سنترال هستند که به سه دلیل از آن استفاده می‌شود که عبارتند از: الف- با توجه به اینکه قشر حسی-حرکتی و قشر پیشانی جزو قشرهایی از مغز هستند که تصمیم‌گیری در بالاترین سطح پیشرفته در مغز را بر عهده دارند. با توجه به آموزش نوروفیدبک انجام شده (یعنی به خاطر آوردن تصاویر متحرک) که یک عمل پیشرفته مغزی است، به نظر می‌رسد از دیدگاه فیزیولوژیکی لوب‌هایی درگیر می‌شوند که سطح تصمیم‌گیری بالاتری نسبت به لوب‌های مغزی دیگر دارند که لوب فرونتال و سنترال هستند.

ب- نمود فرآیند تصورات مغزی در لوب سنترال رخ می‌دهد.

ج- باند آلفا همیشه در لوب اکسیپیتال غالب است ولی در اینجا چون یادآوری یک فرآیند یک عمل پیشرفته است باند آلفا و بتا در دو لوب مغزی سنترال و فرونتال غالب هستند.

۴-۲- ارزیابی نتایج روش پیشنهادی

همان‌طور که بیان شد، برای بررسی نتایج الگوریتم پیشنهادی، از پارامتر صحت مطابق رابطه (۳) استفاده شده که در آن TP درصد کلاس‌های درمان پذیر درست طبقه‌بندی شده، TN درصد کلاس‌های درمان ناپذیر درست طبقه‌بندی شده، FP درصد کلاس‌های درمان پذیر به اشتباه طبقه‌بندی شده و FN درصد کلاس‌های درمان ناپذیر به اشتباه طبقه‌بندی شده است که هر چه عدد این شاخص به یک نزدیک‌تر باشد، بیانگر ایده‌آل بودن روش پیشنهادی است [۳۶، ۳۷]. روش پیشنهادی توانسته تأثیر نوروفیدبک بر درمان‌پذیری و درمان‌ناپذیری بیماران مبتلا به بیش‌فعالی را با صحت ۹۰/۶ پیش‌بینی کند.

۴-۳- پیش پردازش

مطابق پژوهش‌های انجام شده بعضی از الگوهای سیگنال در اثر فیلترگذاری از بین می‌روند، اما تحلیل طیفی سیگنال نشان می‌دهد که الگوهای حذف شده در محدوده فرکانسی باند آلفا و بتا نیستند [۳۸]. در این روش پس از فیلترگذاری شاخص سیگنال به نویز بر حسب دسی‌بل محاسبه می‌شود تا میزان تأثیر فیلتر بر روی سیگنال بررسی شود. در این مقاله محدوده سیگنال مغزی مورد نظر بین ۰/۱ تا ۴۵ هرتز در نظر گرفته شده است.

پس از اعمال فیلتر در بازه مورد نظر (یعنی ۰/۱ تا ۴۵ هرتز)، سیگنال بدون نویز به دست می‌آید که برای محاسبه نسبت سیگنال به نویز باید یک نویز سفید به صورت تصادفی ایجاد کرد و از یک فیلتر بالاگذر ۴۵ هرتز عبور داده شود تا یک نویز صورتی فرکانس بالا به دست آید (چون فقط مقادیر ۴۵ هرتز به بالا مدنظر است) حال برای تست کارایی فیلترها، نویز صورتی ایجاد شده به سیگنال اضافه می‌گردد در نتیجه اگر این فیلترها نویز صورتی مورد نظر را حذف کردند یعنی تمامی نویزها در این بازه را حذف خواهند کرد. در نهایت برای محاسبه SNR توان سیگنال و توان نویز به صورت جداگانه محاسبه و نسبت سیگنال به نویز به دست می‌آید.

جدول (۱) نسبت سیگنال به نویز برای مراحل مختلف فیلترگذاری قبل از اعمال و بعد از اعمال فیلتر را نشان می‌دهد که ردیف‌های این جدول نشان دهنده مراحل فیلترگذاری و ستون‌ها نسبت سیگنال به نویز قبل و بعد از اعمال فیلتر است. همان‌طور که مشاهده می‌شود در فیلتر مرحله اول (فیلتر ناچ) مقدار سیگنال به نویز $2 \pm 1/2$ افزایش یافته است.

Table (1): Signal-to-noise ratio of different stages of filtering before and after applying the filter (dB)
جدول (۱): نسبت سیگنال به نویز مراحل مختلف فیلترگذاری قبل و بعد از اعمال فیلتر (dB)

مراحل فیلترگذاری	قبل از اعمال	بعد از اعمال
فیلتر مرحله اول (فیلتر ناچ)	$55/1 \pm 2/5$	$66/5 \pm 1/3$
فیلتر مرحله دوم (باترورت میان گذر)	$62/3 \pm 2/3$	$74/3 \pm 1/3$
فیلتر مرحله سوم تبدیل موجک فرکانس پایین	$71/6 \pm 2/5$	$82/1 \pm 1/3$
فیلتر مرحله چهارم تبدیل موجک فرکانس بالا	$84/1 \pm 2/2$	$92/5 \pm 1/1$
فیلتر مرحله پنجم میانگین گیر متحرک	$90/5 \pm 2/1$	$98/3 \pm 1/3$

در فیلتر مرحله دوم (باترورت میان گذر) مقدار سیگنال به نویز 2 ± 1 ، در فیلتر مرحله سوم (تبدیل موجک) پایین مقدار سیگنال به نویز $2 \pm 1/2$ ، در فیلتر مرحله چهارم تبدیل موجک فرکانس بالا مقدار سیگنال به نویز $3/4 \pm 0/8$ و در فیلتر مرحله پنجم میانگین گیر متحرک مقدار سیگنال به نویز $3 \pm 0/8$ افزایش یافته است؛ بنابراین نتایج حاصل از مرحله پیش پردازش نشان می‌دهند که اعمال فیلترینگ تبدیل موج فرکانس بالا در مرحله چهارم فیلترینگ بالاترین افزایش در نسبت سیگنال به نویز را دارد و در کل مقدار سیگنال به نویز طی پنج مرحله فیلترگذاری به میزان $7 \pm 1/2$ افزایش یافته است.

$$SNR = \frac{P_{\text{signal}}}{P_{\text{noise}}} \quad (6)$$

شکل (۳) سیگنال مغزی افراد درمان‌پذیر و درمان‌ناپذیر را پیش از انجام فیلتر نشان می‌دهد و در شکل (۴) چگالی طیف توان در حوزه زمان-فرکانس نشان داده شده است که برای تخمین طیف توان از روش ولج استفاده شده است.

۴-۴- پردازش

ویژگی این پژوهش میزان ارتباطات مغزی عملکردی است که برای تشخیص آن از شاخص قفل‌فاز برای دو گروه درمان‌پذیر و درمان‌ناپذیر استفاده می‌شود. برای بیان میزان این ارتباطات از شاخص آماری PV استفاده شده است، اگر عدد PV در دو باند آلفا و بتا برای یک کانال مغزی زیر $0/05$ بود آن کانال انتخاب و اگر بالاتر بود انتخاب نمی‌شوند. پس از کاهش نویز سیگنال با انجام عملیات فیلتراسیون در مرحله پیش‌پردازش، با استفاده از یک فیلتر پاسخ ضربه نامحدود باترورت باندگذر مرتبه ۱۰، دو باند آلفا و بتا استخراج شدند. با کمک الگوریتم ژنتیک و آزمون تی توسط شاخص آماری PV الکترودهای بهینه انتخاب شده‌اند. جدول (۲) کانال‌های مغزی مورد استفاده برای ثبت سیگنال مغزی حین تحریک نوروفیدبک در دو باند آلفا و بتا را نشان می‌دهد که عدد PV برای هر یک از این باندهای فرکانسی به تفکیک محاسبه شده است. در این جدول سطرها شامل اسم کانال‌های مغزی و ستون‌ها عدد PV برای باند آلفا و باند بتا است که مطابق با آن انتخاب یا عدم انتخاب کانال مغزی صورت می‌گیرد. همان‌طور که در شکل (۵) مشاهده می‌شود با توجه به شاخص آماری مورد نظر کانال‌های انتخاب شده در لوب سنترال و فرونتال هستند. که برای تصدیق این ادعا می‌توان دلیل این انتخاب را این‌گونه توجیه کرد:

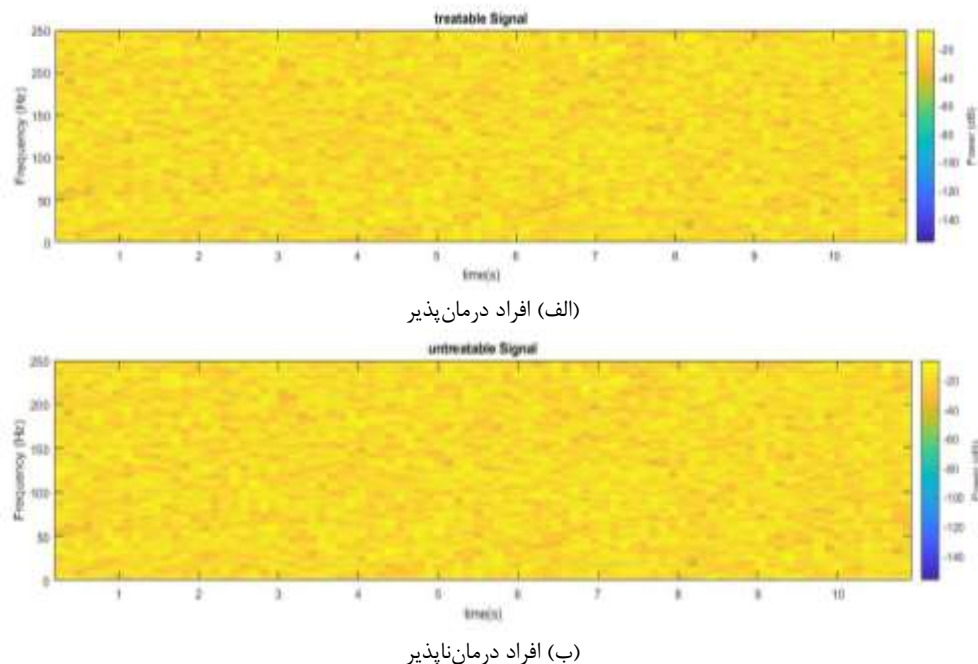
۱- با توجه به اینکه قشر حسی-حرکتی و قشر پیشانی جزو قشرهایی از مغز هستند که تصمیم‌گیری در بالاترین سطح پیشرفته در مغز را بر عهده دارند و با توجه به آموزش نوروفیدبک انجام شده (یعنی به خاطر آوردن تصاویر متحرک) که یک عمل پیشرفته مغزی است به نظر می‌رسد از دیدگاه فیزیولوژیکی لوب‌هایی درگیر میشوند که سطح تصمیم‌گیری بالاتری نسبت به لوب‌های مغزی دیگر دارند که این لوب‌ها، لوب فرونتال و سنترال هستند.

۲- نمود فرآیند تصورات مغزی در لوب سنترال رخ می‌دهد.

۳- باند آلفا همیشه در لوب اکسیپیتال غالب است ولی در اینجا چون یادآوری یک فرآیند یک عمل پیشرفته مغزی است باند آلفا و بتا در دو لوب مغزی سنترال و فرونتال غالب هستند.

شکل‌های (۶) و (۷) استخراج دو باند فرکانسی آلفا و بتا را برای افراد درمان‌پذیر و درمان‌ناپذیر نشان می‌دهند که با توجه به این‌که زمان هر تریال $1/1$ ثانیه است، تریال یک تا ۱۰ (که ۱۱ ثانیه طول می‌کشد) برای ۵۵۰ نمونه در الکتروپنجم (به

دلخواه) در نظر گرفته شده است. در جدول (۳) برای هر یک از باندهای آلفا و بتا کانال‌های مغزی انتخاب شده توسط تست آماری PV با کانال‌های انتخاب شده توسط الگوریتم ژنتیک با حداکثر ارتباطات مغزی مورد بررسی قرار گرفته است. نتایج نشان می‌دهند که شش الکتروود انتخاب شده به کمک الگوریتم ژنتیک با کانال‌های انتخاب شده توسط تست آماری مشابه‌اند و بین الگوریتم ژنتیک و PV تطابق وجود دارد. همان‌طور که مشاهده می‌شود بهترین نتیجه در باند بتا است.




شکل (۴): چگالی طیف توان در حوزه زمان-فرکانس

Figure 4: Power spectrum density in the time-frequency domain

Table (2): Representation of brain channels in terms of number of probability value in alpha and beta bands


جدول (۲): نمایش کانال‌های مغزی برحسب عدد مقدار احتمال در دو باند آلفا و بتا

انتخاب یا عدم انتخاب $P < 0.05$	باند بتا	باند آلفا	کانال مغزی برحسب عدد مقدار احتمال	انتخاب یا عدم انتخاب $P < 0.05$	باند بتا	باند آلفا	کانال مغزی برحسب عدد مقدار احتمال
عدم انتخاب	۰/۰۷	۰/۱	کانال P7	انتخاب	۰/۰۳	۰/۰۴	کانال Cz
	۰/۰۶	۰/۰۸	کانال P4		۰/۰۱	۰/۰۳	کانال C4
	۰/۰۹	۰/۲	کانال Pz		۰/۰۶	۰/۰۴	کانال F4
	۰/۰۷	۰/۰۹	کانال P3		۰/۰۳	۰/۰۳	کانال Fz
	۰/۱	۰/۳	کانال P8		۰/۰۱	۰/۰۳	کانال C3
	۰/۲	۰/۳	کانال O1		۰/۰۲	۰/۰۴	کانال F3
	۰/۵	۰/۲	کانال O2	عدم انتخاب	۰/۲	۰/۵	کانال AF4
	۰/۱	۰/۰۸	کانال T8		۰/۰۶	۰/۰۷	کانال FC2
	۰/۲	۰/۴	کانال F8		۰/۴	۰/۸	کانال FC6
	۰/۰۷	۰/۱	کانال Fp2		۰/۳	۰/۶	کانال PO4
	۰/۳	۰/۷	کانال Fp1		۰/۰۸	۰/۰۶	کانال CP1
	۰/۲	۰/۵	کانال T7		۰/۰۶	۰/۰۹	کانال CP2
	۰/۴	۰/۷	کانال F7		۰/۲	۰/۱	کانال CP6
	۰/۲	۰/۲	کانال Oz		۰/۰۶	۰/۶	کانال FC5
	۰/۰۹	۰/۱	کانال PO3		۰/۵	۰/۹	کانال FC1
	۰/۰۸	۰/۲	کانال AF3		۰/۰۷	۰/۰۸	کانال CP5



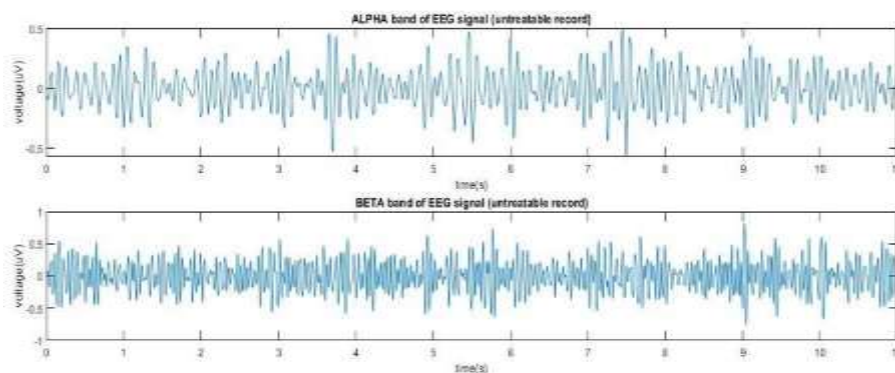
شکل (۵): الکترودهای بهینه در درمان بیماری بیش فعالی با نوروفیدبک

Figure (5): Optimal electrodes effective in the treatment of hyperactivity disease with neurofeedback



شکل (۶): استخراج دو باند آلفا و بتا برای افراد درمان‌پذیر

Figure (6): Extraction of two alpha-beta bands for treatable people



شکل (۷): استخراج دو باند آلفا و بتا برای افراد درمان‌ناپذیر

Figure (7): Extraction of two alpha and beta bands for incurable people

۵-۴- طبقه‌بند

در این پژوهش از طبقه‌بندهای مختلف مانند ماشین بردار پشتیبان، نزدیک‌ترین همسایه و درخت تصمیم‌گیری استفاده شده است و ترکیب این طبقه‌بندها توسط روش بگینگ^{۳۱} و روش بوستینگ^{۳۲} صورت گرفته است.

Table (3): Comparison of brain channels selected by genetic algorithm and statistical test
جدول (۳): مقایسه کانال‌های مغزی انتخاب شده توسط الگوریتم ژنتیک و تست آماری

کانال‌های انتخاب شده توسط تست آماری	کانال‌های منتخب توسط الگوریتم ژنتیک	کانال‌های منتخب توسط الگوریتم ژنتیک با حداکثر اتصال باند بتا
کانال CZ	کانال CZ	کانال CZ
کانال C4	کانال CZ	کانال C4
کانال F4	کانال F4	کانال FZ
کانال FZ	کانال F4	کانال FZ
کانال C3	کانال C3	کانال C3
کانال F3	کانال FZ	کانال F3

در این مرحله ورودی ماتریس ویژگی است که این ماتریس ویژگی ارتباطات مغزی مربوط به الکترودهای بهینه‌ای که بین شاخص PV و الگوریتم ژنتیک مشترک بودند را نشان می‌دهد و ابعاد آن 1200×36 است. ابعاد ماتریس خروجی نیز ۱۲۰۰ در یک است که برچسب درمان‌پذیری یا درمان‌ناپذیری را مشخص می‌کند. در این پژوهش ۶۰۰ نفر درمان‌پذیر با برچسب یک و ۶۰۰ نفر درمان‌ناپذیر با برچسب صفر به‌عنوان ورودی به طبقه‌بند داده شده است.

برای تست طبقه‌بند از کافولد، روش اعتبارسنجی متقابل با ضریب ۵ استفاده شده است. به عبارت دیگر ابتدا داده‌ها به ۵ دسته مساوی تقسیم می‌شوند (زیرا ضریب ۵ بایاس بهتری دارد). با عنایت به این نکته که تعداد داده‌های تست ۲۰ درصد و داده‌های آموزش ۸۰ درصد از کل داده‌های موجود را شامل می‌شوند. در هر مرحله یک دسته از ۵ دسته برای تست و چهار دسته دیگر برای آموزش استفاده می‌شوند. مجدداً در مرحله بعد دسته دیگری به‌جز دسته قبلی به‌عنوان تست و چهار دسته دیگر به‌عنوان آموزش در نظر گرفته می‌شوند تا جایی که تمامی دسته‌ها یک‌بار در مرحله تست قرار بگیرند. در نهایت بین شاخص‌های طبقه‌بندی ۵ مرتبه تست انجام گرفته میانگین‌گیری می‌شود. در جدول‌های طبقه‌بندی سطرها نشان‌دهنده k از یک تا پنج هستند و ستون‌ها نوع کرنل را مشخص می‌کنند. در این جدول‌ها به ازای ۲۰ بار اجرای برنامه، میانگین صحت و انحراف معیار گزارش داده شده که مقادیر سمت راست مثبت و منفی انحراف از معیار و مقادیر سمت چپ میزان صحت را گزارش می‌کنند [۳۹].

در این روش فولدها کاملاً از هم مجزا هستند، به عبارت دیگر آموزش و آزمون هر مرحله به‌طور جداگانه انجام می‌گیرد ولی مجموع صحت‌هایی که از هر فولد به‌دست می‌آید میانگین‌گیری می‌شود تا صحت کلی در همه این ۵ مرحله محاسبه گردد که در نهایت در سطر آخر هر جدول گزارش شده است.

۱-۵-۴- طبقه‌بندی ماشین بردار پشتیبان

ماشین بردار پشتیبان^{۳۳} (SVM) یک مدل یادگیری ماشین با ناظر است که نمونه داده‌هایی موجود در فضا را با استفاده از یک خط یا ابر صفحه از هم جدا می‌کند. این جداسازی به‌گونه‌ای است که نقاط داده‌ای که در یک‌طرف خط هستند مشابه هستند و در یک گروه قرار می‌گیرند و در هر بار طبقه‌بندی نمونه داده‌های جدید هم بعد از اضافه شدن به همان فضا در یکی از دسته‌های موجود قرار خواهند گرفت. هدف از الگوریتم ماشین بردار پشتیبان، یافتن یک ابر صفحه در یک فضای N بعدی (N تعداد ویژگی‌ها) است که نقاط داده را با تفکیک بالا دسته‌بندی می‌کند [۴۰]. در جدول (۴) سطر آخر میانگین اعداد هر کرنل را مشخص کرده که همان‌طور که مشاهده می‌شود طبقه‌بند ماشین بردار پشتیبان با کرنل گوسی ریزمقیاس بالاترین صحت را دارا است و میزان صحت آن $82/22$ برای باند آلفا است. میزان صحت برای باند بتا نیز مانند باند آلفا در کرنل گوسی ریزمقیاس حداکثر بوده و میزان آن $83/06$ است که در جدول (۵) گزارش شده است.

۲-۵-۴- طبقه‌بند نزدیک‌ترین همسایه

(%) Table (4): SVM classification (Alpha band)

جدول (۴): طبقه‌بند ماشین بردار پشتیبان (باند آلفا) (%)

کافولد	کرل خطی	چند جمله‌ای		گوسی	
		درجه دوم	درجه سوم	ریز مقیاس	میان مقیاس
۱	۷۸/۲±۱/۲	۷۹/۲±۱/۲	۷۹/۲±۱/۵	۸۱/۵±۱/۲	۷۹/۵±۱/۲
۲	۷۸/۵±۱/۲	۷۹/۶±۱/۵	۷۹/۵±۱/۲	۸۱/۷±۱/۳	۷۹/۸±۱/۲
۳	۷۹/۵±۱/۵	۸۰/۱±۱/۳	۸۰/۲±۱/۲	۸۲/۳±۱/۵	۸۰/۱±۱/۲
۴	۷۹/۸±۱/۵	۸۱/۲±۱/۵	۸۱/۵±۱/۴	۸۲/۵±۱/۸	۸۰/۵±۱/۵
۵	۸۰/۳±۱/۲	۸۲/۷±۱/۲	۸۲/۵±۱/۷	۸۳/۱±۱/۲	۸۱/۲±۱/۲
میانگین	۷۹/۲۶±۱/۳	۸۰/۵۶±۱/۳۴	۸۰/۵۸±۱/۴	۸۲/۲۲±۱/۴	۸۰/۲۲±۱/۲۶

(%) Table (5): SVM classification (Beta band)

جدول (۵): طبقه‌بند ماشین بردار پشتیبان (باند بتا) (%)

کافولد	کرل خطی	چند جمله‌ای		گوسی	
		درجه دوم	درجه سوم	ریز مقیاس	میان مقیاس
۱	۷۸/۵±۱/۲	۷۹/۸±۱/۲	۸۰/۱±۱/۲	۸۲/۱±۱/۲	۷۹/۲±۱/۴
۲	۷۹/۵±۱/۲	۸۰/۱±۱/۲	۸۰/۵±۱/۲	۸۲/۵±۱/۵	۷۹/۸±۱/۵
۳	۷۹/۵±۱/۵	۸۰/۵±۱/۵	۸۱/۱±۱/۵	۸۳/۱±۱/۲	۸۰/۱±۱/۲
۴	۸۰/۵±۱/۵	۸۱/۲±۱/۵	۸۱/۶±۱/۲	۸۳/۵±۱/۵	۸۰/۲±۱/۵
۵	۸۱/۵±۱/۲	۸۲/۱±۱/۲	۸۳/۱±۱/۵	۸۴/۱±۱/۲	۸۲/۱±۱/۲
میانگین	۷۹/۹±۱/۳۲	۸۰/۷۴±۱/۳	۸۱/۲۸±۱/۳۲	۸۳/۰۶±۱/۳۲	۸۰/۲۸±۱/۳۶

(%) Table (6): KNN classification (Alpha band)

جدول (۶): طبقه‌بند نزدیک‌ترین همسایگی (باند آلفا) (%)

کافولد	فاصله اقلیدسی	سی-تی بلاک منتهن	مینکوفسکی			
			بدون وزن	k برابر ۵	k برابر ۷	k برابر ۹
۱	۷۲/۵±۱/۲	۷۲/۶±۱/۵	۷۳/۲±۱/۲	۷۴/۵±۱/۳	۷۴/۲±۱/۵	۷۳/۲±۱/۵
۲	۷۳/۵±۱/۲	۷۳/۵±۱/۷	۷۴/۶±۱/۵	۷۵/۲±۱/۵	۷۴/۵±۱/۲	۷۳/۶±۱/۲
۳	۷۳/۵±۱/۵	۷۴/۶±۱/۲	۷۴/۸±۱/۲	۷۶/۱±۱/۷	۷۵/۱±۱/۵	۷۴/۳±۱/۵
۴	۷۵/۵±۱/۵	۷۵/۲±۱/۵	۷۵/۱±۱/۵	۷۷/۱±۱/۵	۷۵/۲±۱/۶	۷۵/۲±۱/۵
۵	۷۶/۵±۱/۲	۷۶/۳±۱/۲	۷۶/۲±۱/۶	۷۷/۸±۱/۳	۷۷/۲±۱/۲	۷۶/۷±۱/۶
میانگین	۷۴/۳±۱/۳	۷۴/۴۴±۱/۴۲	۷۴/۷۸±۱/۴	۷۶/۱۴±۱/۴۶	۷۵/۰۴±۱/۴	۷۶/۶±۱/۴۶

Table (7): KNN classification (Beta band) (%)

جدول (۷): طبقه‌بند نزدیک‌ترین همسایه K (باند بتا) (%)

کافولد	فاصله اقلیدسی	سی-تی بلاک منتهن	مینکوفسکی			
			بدون وزن	k برابر ۵	k برابر ۷	k برابر ۹
۱	۷۲/۸±۱/۲	۷۲/۶±۱/۲	۷۳/۹±۱/۱	۷۵/۱±۱/۲	۷۴/۵±۱/۲	۷۴/۱±۱/۸
۲	۷۳/۵±۱/۲	۷۳/۵±۱/۳	۷۴/۶±۱/۵	۷۶/۲±۱/۷	۷۴/۳±۱/۸	۷۵/۸±۱/۲
۳	۷۴/۵±۱/۵	۷۴/۲±۱/۵	۷۵/۸±۱/۲	۷۶/۳±۱/۶	۷۵/۳±۱/۳	۷۶/۲±۱/۱
۴	۷۵/۵±۱/۵	۷۴/۶±۱/۲	۷۶/۲±۱/۵	۷۸/۲±۱/۵	۷۶/۴±۱/۵	۷۷/۵±۱/۲
۵	۷۶/۲±۱/۲	۷۶/۳±۱/۵	۷۷/۳±۱/۸	۷۸/۹±۱/۹	۷۷/۸±۱/۶	۷۹/۱±۱/۲
میانگین	۷۴/۵±۱/۳۲	۷۴/۲۴±۱/۳۴	۷۵/۵۶±۱/۴۲	۷۶/۹۴±۱/۵۸	۷۵/۶۲±۱/۴۸	۷۶/۵۴±۱/۳

الگوریتم نزدیک‌ترین همسایه^{۳۴} (KNN) از تشابه ویژگی برای پیش‌بینی مقادیر نقاط داده جدید استفاده می‌کند [۱/۱] یا به عبارت دیگر به نقطه داده جدید بر اساس میزان مطابقت آن با نقاط مجموعه آموزشی، یک مقدار تخصیص می‌دهد. در جدول (۵) نیز مانند طبقه‌بند ماشین بردار پشتیبان سطرها نشان‌دهنده k از یک تا پنج است و ستون‌ها میزان فاصله نزدیک‌ترین همسایگی را نشان می‌دهند. مطابق جدول‌های (۶) و (۷) در طبقه‌بندی نزدیک‌ترین همسایگی فاصله مینکوفسکی وزن دار k برابر ۵ بالاترین صحت را در دو باند آلفا و بتا دارا است که به تفکیک برای باند آلفا ۷۶/۱۴ و برای باند بتا ۷۶/۹۴ است.

۳-۵-۴- طبقه‌بند درخت تصمیم

درخت تصمیم^{۳۵} یک روش رایج برای نشان دادن فرآیند تصمیم‌گیری به‌وسیله ساختاری درخت مانند و شاخه‌دار است. این روش یکی از رویکردهای دسته‌بندی و رگرسیون در یادگیری ماشین به حساب می‌آید [۴۱، ۴۲]. یک الگوریتم درخت تصمیم برای تقسیم ویژگی‌های مجموعه داده از طریق تابع هزینه مورد استفاده قرار می‌گیرد. در ابتدا این الگوریتم دارای ویژگی‌های نامرتب با مسئله است به همین دلیل باید عملیات بهینه‌سازی و حذف شاخه‌های اضافه بر روی آن صورت گیرد که به آن هرس کردن می‌گویند. در الگوریتم درخت تصمیم، برای جلوگیری از عمل بیش‌برازش یا پیچیدگی بیش‌ازحد درخت، عمق درخت تصمیم را تنظیم می‌کنند. این طبقه‌بند در قالب یک مدل‌سازی پیش‌بینی کننده برای به‌دست آوردن خروجی مطلوب تصمیم‌ها یا راه‌حل‌های مختلف را امتحان می‌کند. در این مقاله سه مدل درخت تصمیم استفاده شده که عبارتند از: ریز-مقیاس، میانه-مقیاس و درشت-مقیاس که برای درخت ریز-مقیاس چهار سطح تجزیه، برای درخت میانه-مقیاس سه سطح تجزیه و برای درخت درشت-مقیاس دو سطح تجزیه در نظر گرفته شده است. تابع یادگیری در این طبقه‌بند نیز الگوریتم ID3 مبتنی بر شاخص بهره اطلاعات^{۳۶} است. در جدول‌های (۸) و (۹) مانند دو طبقه‌بند قبلی، سطرها نشان‌دهنده k از یک تا پنج و ستون‌ها انواع درخت تصمیم را نشان می‌دهند. همان‌طور که مشاهده می‌شود حداکثر صحت در دو باند آلفا و بتا در درخت ریزمقیاس دیده می‌شود که به ترتیب برای باند آلفا ۶۷/۹۴ و برای باند بتا ۶۸/۷۸ است.

۴-۵-۴- ترکیب طبقه‌بند (روش بگینگ و بوستینگ)

دو روش طبقه‌بند بگینگ و بوستینگ با یکدیگر ترکیب شده که بهترین نتیجه را گزارش می‌دهند. بگینگ (کیسه) یک روش یادگیری جمعی است که هدف آن کاهش خطای یادگیری با استفاده از مجموعه‌ای از مدل‌های یادگیری ماشین هم نوع یا همگن است [۴۳]. در ابتدا نوع و تعداد مدل‌های پایه مشخص می‌شود و سپس با کمک رویکرد نمونه‌گیری تصادفی با جایگزینی برای هر مدل پایه یک داده از مجموعه داده‌های آموزشی انتخاب شده و مجدداً آموزش داده می‌شود. برای طبقه‌بندی یک رأی‌گیری ساده بین مدل‌ها اتفاق می‌افتد و داده جدید به کلاسی تعلق می‌گیرد که بیشترین رأی را در مقایسه با سایر کلاس‌ها داشته باشد. ولی برای رگرسیون، یک میانگین‌گیری ساده بین خروجی مدل‌های پایه اتفاق می‌افتد. در روش بوستینگ (افزایشی) با ترکیب موازی یا متوالی تلاش می‌شود تا خطا در حد زیادی کاهش پیدا کند و طبقه‌بندی به بهترین شیوه انجام شود. سیستم یادگیری ضعیف، یادگیرنده‌ای است که به‌عنوان یک طبقه‌بند، تنها کمی بهتر از حالت تصادفی عمل می‌نماید. در مقابل یادگیرنده قوی طبقه‌بندی است که به‌تنهایی می‌تواند برچسب نمونه‌ها را خوبی پیش‌بینی نماید.

Table (8): Decision tree classification (alpha band) (%)

جدول (۸): طبقه‌بند درخت تصمیم (باند آلفا) (%)

کافولد	درخت درشت مقیاس	درخت میانه مقیاس	درخت ریزمقیاس
۱	۶۵/۳±۱/۲	۶۵/۷±۱/۲	۶۶/۲±۱/۵
۲	۶۵/۵±۱/۲	۶۶/۲±۱/۵	۶۷/۱±۱/۲
۳	۶۶/۲±۱/۵	۶۶/۵±۱/۲	۶۸/۵±۱/۷
۴	۶۷/۱±۱/۵	۶۷/۵±۱/۸	۶۸/۸±۱/۲
۵	۶۷/۲±۱/۲	۶۸/۱±۱/۵	۶۹/۱±۱/۵
میانگین	۶۶/۲۶±۱/۳۲	۶۶/۸±۱/۴۴	۶۷/۹۴±۱/۴۲

Table (9): Decision tree classification (beta band) (%)

جدول (۹): طبقه‌بند درخت تصمیم (باند بتا) (%)

کافولد	درخت درشت مقیاس	درخت میانه مقیاس	درخت ریزمقیاس
۱	$65/5 \pm 1/5$	$66/1 \pm 1/2$	$67/5 \pm 1/5$
۲	$65/8 \pm 1/2$	$66/7 \pm 1/5$	$68/2 \pm 1/5$
۳	$67/5 \pm 1/5$	$67/1 \pm 1/2$	$69/3 \pm 1/2$
۴	$67/8 \pm 1/5$	$67/8 \pm 1/7$	$69/8 \pm 1/5$
۵	$68/1 \pm 1/2$	$68/5 \pm 1/2$	$69/1 \pm 1/2$
میانگین	$66/94 \pm 1/38$	$67/24 \pm 1/36$	$68/78 \pm 1/38$

در روش آدابوست (افزایشی تطبیقی)، طبقه‌بند هر مرحله جدید به نفع نمونه‌های غلط طبقه‌بندی شده در مراحل قبل تنظیم می‌گردد. آدابوست نسبت به داده‌های نویزی و پرت حساس است ولی نسبت به مشکل بیش‌برازش از بیشتر الگوریتم‌های یادگیری برتری دارد. طبقه‌بند پایه که در اینجا استفاده می‌شود فقط کافیت از طبقه‌بند تصادفی (۵۰ درصد) بهتر باشد و به این ترتیب بهبود عملکرد الگوریتم با تکرارهای بیشتر بهبود می‌یابد. حتی طبقه‌بندهای با خطای بالاتر از تصادفی با گرفتن ضریب منفی عملکرد کلی را بهبود می‌بخشند. در الگوریتم آدابوست^{۳۷} در هر دور یک طبقه‌بند ضعیف اضافه می‌شود. در هر فراخوانی بر اساس اهمیت نمونه‌ها، وزن‌ها به روز می‌شود. در هر دور وزن نمونه‌های غلط طبقه‌بندی شده افزایش و وزن نمونه‌های درست طبقه‌بندی شده کاهش داده می‌شود؛ بنابراین طبقه‌بند جدید تمرکز بر نمونه‌هایی که سخت‌تر یاد گرفته می‌شوند، خواهند داشت [۴۴]. در جدول‌های (۱۰) و (۱۱) سطرها k از یک تا پنج و ستون‌ها روش‌های ترکیب طبقه‌بند را نشان می‌دهند که روش کیسه همان روش بگینگ و روش افزایشی و افزایشی تطبیقی همان روش بوستینگ است. همان‌طور که مشاهده می‌شود روش افزایشی تطبیقی بوستینگ دارای حداکثر صحت بوده که برای باند آلفا ۸۹/۶۲ و برای باند بتا ۹۰/۶ است و به‌عنوان بهترین ترکیب طبقه‌بندی انتخاب می‌شود. از جمع‌بندی جدول‌های (۴) الی (۹) که نتایج طبقه‌بندی بین سه نوع طبقه‌بند را نشان می‌دهد، می‌توان نتیجه گرفت که در طبقه‌بند ماشین بردار پشتیبان، کرنل گوسی ریزمقیاس، در طبقه‌بند نزدیک‌ترین همسایه، فاصله مینکوفسکی وزن‌دار k برابر ۵ و در طبقه‌بند درخت، تصمیم درخت ریزمقیاس بالاترین بازدهی‌ها را دارا بوده‌اند. نکته دیگر این‌که تمامی نتایج بیان‌شده برای باند بتا دارای ضرایب بالاتری نسبت به باند آلفا هستند و در نهایت از بین این سه طبقه‌بند، طبقه‌بند ماشین بردار پشتیبان با کرنل گوسی ریزمقیاس در باند بتا دارای بالاترین صحت ۸۳/۰۶ است؛ بنابراین می‌توان بیان کرد که ماشین بردار پشتیبان بهترین طبقه‌بند برای ویژگی مورد نظر است. از جمع‌بندی جدول‌های (۱۰) و (۱۱) چنین استنتاج می‌شود که در ترکیب طبقه‌بندها روش بوستینگ، در روش افزایشی تطبیقی بیشترین کارایی را دارا است و نتایج برای باند بتا دارای ضرایب بالاتری نسبت به باند آلفا بوده و در نتیجه روش بوستینگ در روش افزایشی تطبیقی باند بتا با صحت ۹۰/۶ بهترین ترکیب طبقه‌بند را ارائه می‌دهد. همان‌طور که مشاهده می‌شود روش پیشنهادی بالاترین صحت را در بین تحقیقات اخیر برای پیش‌بینی درمان‌پذیری بیماران مبتلا به بیش‌فعالی داشته است. (تمامی مقادیر گزارش شده در جدول‌های بالا با واحد درصد محاسبه شده است). جدول (۱۲) مقایسه بهترین خروجی در طبقه‌بندهای مختلف در دو باند آلفا و بتا را نشان می‌دهد.

Table (10): Combination of classifications with bagging and boosting method (alpha band) (%)

جدول (۱۰): ترکیب طبقه‌بندها با روش بگینگ و بوستینگ (باند آلفا) (%)

کافولد	روش کیسه	روش افزایشی	روش افزایشی تطبیقی
۱	$86/2 \pm 1/2$	$86/2 \pm 1/2$	$88/1 \pm 1/2$
۲	$86/5 \pm 1/5$	$86/9 \pm 1/5$	$89/2 \pm 1/5$
۳	$87/5 \pm 1/5$	$88/4 \pm 1/2$	$89/5 \pm 1/2$
۴	$87/8 \pm 1/5$	$88/5 \pm 1/5$	$90/1 \pm 1/2$
۵	$89/1 \pm 1/2$	$90/2 \pm 1/1$	$91/2 \pm 1/5$
میانگین	$87/42 \pm 1/38$	$88/04 \pm 1/3$	$89/62 \pm 1/32$

Table (11): Combination of classifications with bagging and boosting method (Beta Band) (%)

جدول (۱۱): ترکیب طبقه بندی با روش بگینگ و بوستینگ (باند بتا) (%)

کافولد	روش کیسه	روش افزایشی	روش افزایشی تطبیقی
۱	$86/5 \pm 1/2$	$87/5 \pm 1/2$	$89/1 \pm 1/5$
۲	$87/5 \pm 1/2$	$88/5 \pm 1/5$	$90/5 \pm 1/2$
۳	$87/9 \pm 1/5$	$88/7 \pm 1/5$	$90/8 \pm 1/5$
۴	$88/8 \pm 1/8$	$90/5 \pm 1/2$	$91/1 \pm 1/1$
۵	$89/6 \pm 1/2$	$90/7 \pm 1/1$	$91/5 \pm 1/5$
میانگین	$88/06 \pm 1/38$	$89/18 \pm 1/3$	$90/6 \pm 1/36$

Table (12): Comparison of the best output in different categories in two alpha and beta bands (%)

جدول (۱۲): مقایسه بهترین خروجی در طبقه بندیهای مختلف در دو باند آلفا و بتا (%)

صحت باند بتا	صحت باند آلفا	بهترین بر آورد	طبقه بندی
$68/78 \pm 1/38$	$67/94 \pm 1/42$	درخت ریزمقیاس	درخت تصمیم
$83/06 \pm 1/32$	$82/22 \pm 1/4$	گوسی ریزمقیاس	ماشین بردار پشتیبان
$76/94 \pm 1/58$	$76/14 \pm 1/46$	مینکوفسکی وزن دار	نزدیکترین همسایگی
$90/6 \pm 1/36$	$89/62 \pm 1/32$	روش افزایشی تطبیقی	ترکیب طبقه بندیها

Table (13): Comparison of the accuracy percentage of the proposed method and a number of researches

جدول (۱۳): مقایسه درصد صحت روش پیشنهادی و تعدادی از تحقیقات

ردیف	صحت (درصد)	تعداد بیمار	تعداد جلسات	روش	مرجع
۱	۷۰	۱۸	بدون آموزش	توموگرافی الکترومغناطیسی مغز	[۴۵]
۲	۴۵/۵	۴۶	۱۰-۲۸	تمرین ترکیبی تتا/بتا (۱۸ جلسه) و همچنین تمرکز بر پتانسیل های آهسته قشر مغز	[۴۶]
۳	۷۹/۶	۲۳ کودک ۹ تا ۱۲ سال	بدون آموزش	بررسی پتانسیل های آهسته قشر مغز با توجه به معیار سن و جنسیت	[۴۷]
۴	۸۹/۹	۲۰	۱-۶	بررسی پتانسیل های آهسته قشر مغز بیماران در طول شش جلسه اول (۵ تا ۸ ثانیه حین فعالیت)	[۴۸]
۵	۹۰/۶	۶۰	بدون آموزش	بررسی میزان ارتباطات مغزی عملکردی با استفاده از شاخص قفل فاز	روش پیشنهادی

۴-۶- مقایسه درصد صحت روش پیشنهادی با مطالعات گذشته

در جدول (۱۳) مقایسه درصد صحت روش پیشنهادی با تعدادی از مطالعات انجام شده آمده است. همان طور که مشاهده می شود در مورد اول (روش توموگرافی الکترومغناطیسی مغز)، تعداد ۱۸ بیمار مبتلا به بیش فعالی مورد بررسی قرار گرفته اند و قبل از شروع درمان با نوروفیدبک با بررسی توموگرافی الکترومغناطیسی، درمان پذیری با صحت ۷۰ درصد پیش بینی شده است. در مورد دوم، تمرکز بر پتانسیل قشر آهسته مغز (SCP) و همچنین تمرین ترکیبی تتا/بتا (۱۸ جلسه) پیش از شروع درمان بر روی ۴۶ بیمار انجام شده و نتیجه پس از تجزیه و تحلیل رگرسیون خطی به این ترتیب بوده که هیچ متغیر پیش بینی کننده قابل توجهی برای نتایج آموزش کامل تتا/بتا+SCP به دست نیامده است. با این حال، در بلوک تمرینی تتا/بتا، کاهش بیشتر فعالیت تتا در طول تمرین نسبت به قبل از آموزش نوروفیدبک، در افراد درمان پذیر وجود دارد. همچنین برای بلوک آموزشی SCP، افزایش بیشتر آلفا در طول تمرین، نسبت به قبل از آموزش در افراد درمان پذیر وجود دارد و در نهایت نتایج آموزش نوروفیدبک با صحت ۴۵/۵ درصد پیش بینی شده است. در مورد سوم، تعداد ۲۳ کودک ۹ تا ۱۲ سال مبتلا به بیش فعالی با معیار SCP و معیار سن و جنسیت مورد بررسی قرار گرفته اند و نتایج نشان می دهند که این معیارها به خصوص معیار سن افراد، می تواند شرایط شروع متفاوتی برای تمرینات نوروفیدبک را در کودکان ایجاد کند. مطابق بررسی داده های EEG قبل از آموزش، کاهش فعالیت در باندهای فرکانسی کندتر و کاهش نسبت تتا/بتا با افزایش سن وجود دارد. از طرفی

تفاوتی بین دختران و پسران در مورد عملکرد یادگیری نوروفیدبک در بیماران ADHD وجود ندارد و در نهایت در این روش با صحت ۷۹/۶ درصد میزان درمان‌پذیری پیش از شروع آموزش نوروفیدبک پیش‌بینی شده است. در مورد چهارم، تعداد ۲۰ بیمار در طول شش جلسه اول (۵ تا ۸ ثانیه حین فعالیت) مورد مطالعه قرار گرفته‌اند. در این روش با استفاده از معیار SCP نشان داده شده که در EEG افراد درمان‌پذیر نسبت به درمان‌ناپذیر افزایش واضح SCP مثبت صورت می‌گیرد و در نتیجه با صحت ۸۹/۹ درصد افراد درمان‌پذیر و درمان‌ناپذیر طبقه‌بندی شده‌اند. و در نهایت در روش پیشنهادی تعداد ۶۰ بیمار قبل از شروع درمان با نوروفیدبک مورد بررسی قرار گرفته‌اند و با بررسی میزان ارتباطات مغزی عملکردی با استفاده از شاخص قفل فاز، درمان‌پذیری با صحت ۹۰/۶ درصد پیش‌بینی شده است.

۵- نتیجه‌گیری

اختلال بیش‌فعالی-نقص توجه یکی از شایع‌ترین اختلالات تکاملی عصبی دوران کودکی است که می‌توان آن را با روش نوروفیدبک تا حد زیادی بهبود بخشید. در این مقاله در گام اول تعداد ۶۰ دانش‌آموز مبتلا به بیش‌فعالی تحت درمان قرار گرفته‌اند که سیگنال مغزی جلسات ۱۰ تا ۲۰ دوره درمانی برای پردازش در نظر گرفته شده است. ثبت‌ها با آرتیفکت حرکتی و نویزهای محیطی همراه بودند که با ۵ مرحله فیلترگذاری حذف شدند. دو باند آلفا و بتا با استفاده از یک فیلتر باترورت میان‌گذر مرتبه ۱۰ استخراج و مورد پردازش قرار گرفتند. سپس با استفاده از شاخص قفل‌فاز لوب‌های مغزی دارای ارتباط عملکردی تشخیص و الکترودهای موثر در آموزش نوروفیدبک که در دو لوب فرونتال و سنترال بودند، استخراج شدند که یک‌بار به وسیله الگوریتم ژنتیک و بار دیگر توسط شاخص آماری PV الکترودهای بهینه تشخیص و با اشتراک گرفتن از این دو روش تعداد آن از ۳۲ کانال به ۶ کانال کاهش یافت. در نهایت ماتریس ویژگی که همان شاخص قفل‌فاز است به‌عنوان ورودی به طبقه‌بندها داده شد و از طریق روش ترکیب طبقه‌بندی صحت روش مورد بررسی قرار گرفت. از الگوریتم ژنتیک برای انتخاب الکترودهای بهینه استفاده شده که تعداد ۳۲ الکترودهای ثابت را به ۶ الکترودهای کاهش داده که یکی از مزایای الگوریتم پیشنهادی است زیرا می‌تواند الکترودهای مؤثر در درمان نوروفیدبک را مشخص کند. نتایج نشان دادند که در بین طبقه‌بندی‌ها ماشین بردار پشتیبان و در ترکیب طبقه‌بندها روش افزایشی بیشترین صحت را دارا هستند. در نتیجه الگوریتم پیشنهادی در کوتاه‌ترین زمان و با تعداد داده محدود با صحت ۹۰/۶ درصد درمان‌پذیری افراد مبتلا به بیش‌فعالی را در روش نوروفیدبک پیش‌بینی می‌کند. همچنین الگوریتم پیشنهادی می‌تواند در کلینیک‌های روانشناسی به کار برده شود و از تحمیل بار روحی و اتلاف هزینه و زمان در بیماران درمان‌ناپذیر جلوگیری کند.

سپاسگزاری

این مقاله مستخرج از پایان‌نامه دوره کارشناسی‌ارشد در دانشگاه آزاد اسلامی واحد نجف‌آباد است. نویسندگان بر خود لازم می‌دانند مراتب تشکر صمیمانه خود را از همکاران حوزه پژوهشی دانشگاه آزاد اسلامی و داوران محترم که ما را در انجام و ارتقای کیفی این مقاله یاری نموده‌اند، اعلام نمایند.

References

مراجع

- [1] K. Molinero, J.D. Hinckley, "Adolescent cannabis use, comorbid attention-deficit/hyperactivity disorder, and other internalizing and externalizing disorders", *Child and Adolescent Psychiatric Clinics of North America*, vol. 32, no. 1, pp. 57-68, Jan. 2023 (doi: 10.1016/j.chc.2022.07.003).
- [2] G. Deshpande, P. Wang, D. Rangaprakash, B. Wilamowski, "Fully connected cascade artificial neural network architecture for attention deficit hyperactivity disorder classification from functional magnetic resonance imaging data", *IEEE Trans. on Cybernetics*, vol. 45, no. 12, pp. 2668-2679, Dec. 2015 (doi: 10.1109/TCYB.2014.2379621).
- [3] M. Dorvashi, N. Behzadfar, G. Shahgholian, "Classification of alcoholic and non-alcoholic individuals based on frequency and non-frequency features of electroencephalogram signal", *Journal Iranian Journal of Biomedical Engineering*, vol. 14, no. 2, pp. 121-130, July 2020 (doi: 10.22041/ijbme.2020.119841.1551).

- [4] H. Gevensleben, B. Høi, B. Albrecht, D. Schlamp, O. Kratz, P. Studer, S. Wangler, A. Rothenberger, G.H. Moii, H. Heinrich, "Distinct EEG effects related to neurofeedback training in children with ADHD: A randomized controlled trial", *International Journal of Psychophysiology*, vol. 74, no. 2, pp. 149-157, Sept. 2019 (doi: 10.1016/j.ijpsycho.2009.08.005).
- [5] P. Jalali, N. Sho'ouri, "Neurofeedback training protocol based on selecting distinctive features to treat or reduce ADHD symptoms", *Clinical EEG and Neuroscience*, vol. 52, no. 6, pp. 414-421, Nov. 2021 (doi: 1-0.1177/1550059421-1033435).
- [6] A. Zuberer, D. Brandeis, R. Drechsler, "Are treatment effects of neurofeedback training in children with ADHD related to the successful regulation of brain activity? A review on the learning of regulation of brain activity and a contribution to the discussion on specificity", *Frontiers in Human Neuroscience*, vol. 9, Article Number: 135, Mar. 2015 (doi: 10.3389/fnhum.2015.00135).
- [7] E. Weber, A. Köberl, S. Frank, M. Doppelmayr, "Predicting successful learning of SMR neurofeedback in healthy participants: methodological considerations", *Applied Psychophysiology and Biofeedback*, vol. 36, no. 1, pp. 37-45, March 2011 (doi: 10.1007/s10484-010-9142-x).
- [8] A.K. Dubey, A. Saxena, A. Kumar, A. Rai, "Attention deficit hyperactivity disorder (ADHD) prediction system", *Proceeding of the ICSCDS, Erode, India*, pp. 1321-1325, 2022 (doi: 10.1109/ICSCDS53736.2022.9760921).
- [9] A. Tobeiha, N. Behzadfar, M.R. Yousefi-Najafabadi, H. Mahdavi-Nasab, G. Shahgholian, "Choosing the distinguishing frequency feature of people addicted to heroin from healthy while resting", *Signal and Data Processing*, vol. 19, no. 3, pp. 49-64, Dec. 2022 (doi: 10.52547/jsdp.19.3.49).
- [10] X.Y. Chen, L. Sui, "Alpha band neurofeedback training based on a portable device improves working memory performance of young people", *Biomedical Signal Processing and Control*, vol. 80, Article Number: 104308, Feb. 2023 (doi: 10.1016/j.bspc.2022.104308).
- [11] N. Behzadfar, "A brief overview on analysis and feature extraction of electroencephalogram signals", *Signal Processing and Renewable Energy*, vol. 6, no. 1, pp. 39-64, March 2022 (dor: 20.100-1.1.25887327.2022.6.1.3.9).
- [12] S. Karimi-Shahraki, M. Khezri, "Identification of attention deficit Hyperactivity disorder patients using wavelet-based features of EEG signals", *Journal of Intelligent Procedures in Electrical Technology*, vol. 12, no. 47, pp. 1-11, Dec. 2021 (dor: 20.1001.1.23223871.1400.12.3.1.1).
- [13] M. Dorvashi, N. Behzadfar, G. Shahgholian, "Electroencephalogram signal during neurofeedback training", *Signal and Data Processing*, vol. 19, no. 3, pp. 163-174, Dec. 2022 (doi: 10.52547/jsdp.19.3.163).
- [14] E. Dudek, D. Dodell-Feder, "The efficacy of real-time functional magnetic resonance imaging neurofeedback for psychiatric illness: A meta-analysis of brain and behavioral outcomes", *Neuroscience and Biobehavioral Reviews*, vol. 121, pp. 291-306, Feb. 2021 (doi: 10.1016/j.neubiorev.2020.12.020).
- [15] W. Nan, F. Wang, M. Vaim A.C. Rosa, "Resting and initial beta amplitudes predict learning ability in beta/theta ratio neurofeedback training in healthy young adults", *Frontiers in Human Neuroscience*, vol. 9, Article Number: 677, Dec. 2015 (doi: 10.3389/fnhum.2015.00677).
- [16] T.W.P. Janssen, M. Bink, W.D. Weeda, K. Geladé, R. Mourik, A. Maras, J. Oosterlaan, "Learning curves of theta/beta neurofeedback in children with ADHD", *European Child and Adolescent Psychiatry*, vol. 26, no. 5, pp. 573-582, 2017 (doi: 10.1007%2Fs00787-016-0920-8).
- [17] H. Marzbani, H.R. Marateb, M. Mansourian, "Neurofeedback: A comprehensive review on system design, methodology and clinical applications", *Basic and Clinical Neuroscience*, vol. 7, no. 2, pp. 143-58. 2016 (doi: 10.15412/j.bcn.03070208).
- [18] K.J. Friston, "Functional and effective connectivity: A review", *Brain connectivity*, vol. 1, no. 1, pp. 13-36, 2011 (doi: 10.1089/brain.2011.0008).
- [19] F. Mottola, A. Blanchfield, J. Hardy, A. Cooke, "EEG neurofeedback improves cycling time to exhaustion", *Psychology of Sport and Exercise*, vol. 55, Article Number: 101944, July 2021 (doi: 10.1016/j.psychsport.2-021.101944).
- [20] M. Iyzadpanahi, M.R. Yousefi, N. Behzadfar, "Classification of upper limb movement imaginations based on a hybrid method of wavelet transform and principal component analysis for brain-computer interface applications", *Journal of Novel Researches on Electrical Power*, vol. 9, no. 3, pp. 35-42, Dec. 2020 (dor: 20.1001.1.23222468.1399.9.3.4.6).
- [21] M. Dorvashi, N. Behzadfar, G. Shahgholian, "An efficient method for classification of alcoholic and normal electroencephalogram signals based on selection of an appropriate feature", *Journal of Medical Signals and Sensors*, vol.13, no. 1, pp. 11-20, March 2023 (doi: 10.4103/jmss.jmss_183_21).
- [22] Z. Agnieszka, D. Brandeis, and R. Drechsler, "Are treatment effects of neurofeedback training in children with ADHD related to the successful regulation of brain activity? A review on the learning of regulation of brain activity and a contribution to the discussion on specificity", *Frontiers in Human Neuroscience*, vol. 9, Article Number: 135, Mar. 2015 (doi: 10.3389/fnhum.2015.00135).

- [23] M.P. Deiber, R. Hasler, J. Colin, A. Dayer, J.M. Aubry, S. Baggio, N. Perroud, T. Ros, "Linking alpha oscillations, attention and inhibitory control in adult ADHD with EEG neurofeedback", *NeuroImage: Clinical*, vol. 25, Article Number: 102145, 2020 (doi: 10.1016/j.nicl.2019.102145).
- [24] J.H. Gruzelier, P. Holmes, L. Hirst, K. Bulpin, S. Rahman, C. van Run, J. Leach, "Replication of elite music performance enhancement following alpha/theta neurofeedback and application to novice performance and improvisation with SMR benefits", *Biological Psychology*, vol. 95, pp. 96-107, Jan. 2014 (doi: 10.1016/j.biopsycho.2013.11.001).
- [25] G.W. Hynd, A.R. Lorys, M. Semrud-Clikeman, N. Nieves, M.I. Huettnner, B.B. Lahey, "Attention deficit disorder without hyperactivity: a distinct behavioral and neurocognitive syndrome", *Journal of Child Neurology*, vol. 6, no. 1, pp. 37-43, June 1991 (doi: 0883073891006001s05).
- [26] J.C. Edgar, C.L. Fisk, Y.H. Chen, B. Stone-Howell, M.A. Hunter, M. Huang, J.R. Bustillo, J.M. Cañive, "By our bootstraps: Comparing methods for measuring auditory 40 Hz steady-state neural activity", *Psychophysiology*, vol. 54, no. 8, pp. 1110-1127, April 2017 (doi: 10.1111/psyp.12876).
- [27] H. Fathi-Sanghari, N. Behzadfar, "Application of firefly algorithm in automatic extraction of brain tumor from multi-modality magnetic resonance images", *International Journal of Smart Electrical Engineering*, vol. 10, no. 4, pp. 187-196, 2021 (doi: 10.30495/ijsee.2021.684023).
- [28] F.H. Garabaghi, R. Benzer, S. Benzer, A.Ç. Günel, "Effect of polynomial, radial basis, and Pearson VII function kernels in support vector machine algorithm for classification of crayfish", *Ecological Informatics*, vol. 72, Article Number: 101911, Dec 2022 (doi: 10.1016/j.ecoinf.2022.101911).
- [29] M. Azzeh, Y. Elsheikh, A.B. Nassif, L. Angelis, "Examining the performance of kernel methods for software defect prediction based on support vector machine", *Science of Computer Programming*, vol. 226, Article Number: 102916, March 2023 (doi: 10.1016/j.scico.2022.102916).
- [30] N. Dashti, M. Khezri, "Recognition of motor imagery based on dynamic features of EEG signals", *Journal of Intelligent Procedures in Electrical Technology*, vol. 11, no. 43, 13-27, December 2020 (in Persian) (dor: 20.1001.1.23223871.1399.11.43.2.5).
- [31] Z. Wang, C.M. Wong, W. Nan, Q. Tang, A.C. Rosa, P. Xu, F. Wan, "Learning curve of a short-time neurofeedback training: Reflection of brain network dynamics based on phase-locking value", *IEEE Trans. on Cognitive and Developmental Systems*, vol. 14, no. 3, pp. 1282-1295, Sept. 2022 (doi: 10.1109/TCDS.2021.3125948).
- [32] A.V. Sazonov, C.K. Ho, J.W. Bergmans, J.B. Arends, P.A. Griep, E.A. Verbitskiy, P.J. Cluitmans, P.A. Boon, "An investigation of the phase locking index for measuring of interdependency of cortical source signals recorded in the EEG", *Biological Cybernetics*, vol. 100, no. 2, pp. 129-146, Feb. 2009 (doi: 10.1007/s0042200802834).
- [33] J.H. Gruzelier, "A theory of alpha/theta neurofeedback, creative performance enhancement, long distance functional connectivity and psychological integration", *Cognitive Processes*, vol. 10, op. 101-110, Feb. 2009 (doi: 10.1007/s10339-008-0248-5).
- [34] S. Majlesi, M. Khezri, "Stress detection based on fusion of multimodal physiological signals using Dempster-Shafer evidence theory", *Journal of Intelligent Procedures in Electrical Technology*, vol. 13, no. 52, pp. 99-110, March 2023 (dor: 20.1001.1.23223871.1401.13.52.7.2).
- [35] M. Seif, M.R. Yousefi, N. Behzadfar, "EEG spectral power analysis: A comparison between heroin dependent and control groups", *Clinical EEG and Neuroscience*, vol. 53, no. 4, Article Number: 15500594221089366, March 2022 (doi: 10.1177/15500594221089366).
- [36] H. Li, L. Wu, "EEG classification of normal and alcoholic by deep learning", *Brain Sciences*, vol. 12, no. 6, Article Number: 778, June 2022 (doi: 10.3390/brainsci12060778).
- [37] M. Shafiof, N. Behzadfar, "Diagnosis of brain tumor position in magnetic resonance images by combining bounding box algorithms, artificial bee colonies and grow cut", *International Journal of Smart Electrical Engineering*, vol. 11, no. 1, pp. 1-12, March 2022 (dor: 20.1001.1.22519246.2022.11.1.1.7).
- [38] J.F. Harmsel, M.L. Noordzij, A.E. Goudriaan, J.J.M. Dekker, L.T.A. Swinkels, T.M. Pol, A. Popma, "Biofeedback and ambulatory biofeedback to enhance emotion regulation: A review of studies investigating non-psychiatric and psychiatric populations", *International Journal of Psychophysiology*, vol. 159, pp. 94-106, Jan. 2021 (doi: 10.1016/j.ijpsycho.2020.11.009).
- [39] E. Hurt, L.E. Arnold, N. Lofthouse, "Quantitative EEG neurofeedback for the treatment of pediatric attention-deficit/hyperactivity disorder, autism spectrum disorders, learning disorders, and epilepsy", *Child and Adolescent Psychiatric Clinics of North America*, vol. 23, no. 3, pp. 465-486, July 2014 (doi: 10.1016/j.chc.2014.02.001).
- [40] S. Bartholdy, P. Musiat, I.C. Campbell, U. Schmidt, "The potential of neurofeedback in the treatment of Eating Disorders: A Review of the Literature", *European Eating Disorders Review*, vol. 21, no. 6, pp. 456-463, Sept. 2013 (doi: 10.1002/erv.2250).

- [41] D.R. Simkin, R.W. Thatcher, J. Lubar, "Quantitative EEG and neurofeedback in children and adolescents: anxiety disorders, depressive disorders, comorbid addiction and attention-deficit/hyperactivity disorder, and brain injury", *Child and Adolescent Psychiatric Clinics of North America*, vol. 23, no. 3, pp. 427-464, July 2014 (doi: 10.1016/j.chc.2014.03.001).
- [42] S. Roy, N. Mandal, A. Ray, P.K. Roy, A. Bhattacharyya, P.K. Saha, "Effectiveness of neurofeedback training, behaviour management including attention enhancement training and medication in children with attention-deficit/hyperactivity disorder- A comparative follow up study", *Asian Journal of Psychiatry*, vol. 76, Article Number: 103133, Oct. 2022 (doi: 10.1016/j.ajp.2022.103133).
- [43] Y. Gil, G. Li, J. Lee, "Integrated real-time neurofeedback system to raise the frontal lobe activity: Design and implementation", *Proceeding of the IEEE/IEMBS*, pp. 845-848, MN, USA, Sept. 2009 (doi: 10.1109/IEMBS.2009.5333098).
- [44] Y. Freund, R.E. Schapire, "A decision-theoretic generalization of on-line learning and an application to boosting", vol. 55, no. 1, pp. 119-139, Aug. 1997 (doi: 10.1006/jcss.1997.1504).
- [45] W. Nan, F. Wan, Q. Tang, C.M. Wong, B. Wang, A. Rosa, "Eyes-closed resting EEG predicts the learning of alpha down-regulation in neurofeedback training", *Frontiers in Psychology*, vol. 9, Article Number: 30210419, Aug. 2018 (doi: 10.3389/fpsyg.2018.01607).
- [46] T.F. Collura, J. Guan, J. Tarrant, J. Bailey, F. Starr, "EEG biofeedback case studies using live Z-score training and a normative database", *Journal of Neurotherapy*, vol. 14, no. 1, pp. 22-46, Feb. 2010 (doi: 10.1080/10874200903543963).
- [47] M. Arns, J. Gunkelman, M. Breteler, D. Spronk, "EEG phenotypes predict treatment outcome to stimulants in children with ADHD", *Journal of Integrative Neuroscience*, vol. 7, no. 3, pp. 421-438, Sept. 2008 (doi: 10.1142/s0219635208001897).
- [48] Y. Okumura, Y. Kita, M. Omori, K. Suzuki, A. Yasumura, A. Fukuda, M. Inagaki, "Predictive factors of success in neurofeedback training for children with ADHD", *Developmental Neurorehabilitation*, vol. 22, no. 1, pp. 3-12, Jan. 2019 (doi: 10.1080/17518423.2017.1326183).

زیر نویس‌ها

- | | |
|---|----------------------------------|
| 1. Attention-deficit hyperactivity disorder | 32. Boosting |
| 2. Attention deficit disorder | 33. Support vector machine |
| 3. Temporal lobe | 34. K-nearest neighbors |
| 4. Parietal- temporal lobe | 35. Decision tree classification |
| 5. Occipital- temporal lobes | 36. Iterative dichotomiser 3 |
| 6. Neurofeedback | 37. Adaboost |
| 7. treatability | |
| 8. Slow cortical potential | |
| 9. Low energy neurofeedback system | |
| 10. Hemoencephalography neurofeedback | |
| 11. Live Z-score neurofeedback | |
| 12. Low resolution electromagnetic tomography | |
| 13. Functional magnetic resonance imaging | |
| 14. Perceptual-cognitive | |
| 15. Bandpass butterworth filter | |
| 16. Anatomical relationship | |
| 17. Phase locking value | |
| 18. Probability value | |
| 19. T-test | |
| 20. Genetic algorithm | |
| 21. Accuracy | |
| 22. Mendeley | |
| 23. Notch filter | |
| 24. McClan's algorithm | |
| 25. Wavelet Transform | |
| 26. Signal to noise ratio | |
| 27. Moving average filter | |
| 28. Motion artifact | |
| 29. Fitness Function | |
| 30. Flipbit | |
| 31. Bagging | |